

Visión por Computadora e Inteligencia Artificial en Sistemas de Transporte Inteligentes y Monitoreo de Conductores: Un Estado del Arte

Clinio Omar Rayme Huacho
Ingeniería Informática y Sistemas
Universidad Nacional Micaela Bastidas
Abancay, Perú
192223@unamba.edu.pe

Cristian Mosqueira Huamanñahui
Ingeniería Informática y Sistemas
Universidad Nacional Micaela Bastidas
Abancay, Perú
181223@unamba.edu.pe

Resumen—Este artículo presenta una revisión sistemática del estado del arte en el uso de técnicas de Inteligencia Artificial (IA) y Visión Computacional aplicadas a los Sistemas de Transporte Inteligentes (ITS) y al Monitoreo del Comportamiento de Conductores. Analizando un corpus de 213 publicaciones científicas recientes (2020–2026), clasificamos y contrastamos los enfoques metodológicos predominantes, que abarcan desde el aprendizaje profundo (Deep Learning) hasta el aprendizaje automático tradicional (Machine Learning) y técnicas de visión híbridas. Evaluamos los entornos experimentales más comunes (sistemas de videovigilancia CCTV, drones/UAV y pruebas en entornos reales), las plataformas de hardware y software empleadas para su implementación, así como las métricas de rendimiento y limitaciones reportadas en la literatura. Los resultados demuestran una clara transición hacia modelos de aprendizaje profundo en años recientes y un auge en el despliegue en hardware de borde (Edge Computing), enfrentando retos persistentes relacionados con oclusiones visuales y variaciones extremas en las condiciones de iluminación.

Index Terms—Sistemas de Transporte Inteligentes, Visión Computacional, Deep Learning, Monitoreo de Conductores, Detección de Infracciones, Aprendizaje Automático.

I. INTRODUCCIÓN

Los Sistemas de Transporte Inteligentes (ITS, por sus siglas en inglés) y el monitoreo del comportamiento de conductores representan pilares fundamentales en la evolución de las ciudades inteligentes y la seguridad vial global. Ante el aumento en el riesgo de siniestros, resulta crucial desarrollar soluciones tecnológicas automatizadas, no invasivas y en tiempo real para supervisar y regular las conductas viales [1, 2]. Tradicionalmente dependientes de auditorías manuales o de sensores físicos de hardware invasivos y de alto costo (como bucles de inducción o radares), el advenimiento del procesamiento digital de imágenes y el aprendizaje profundo ha propiciado un cambio de paradigma hacia sistemas inteligentes basados en cámaras ópticas que procesan video en tiempo real de forma inteligente [3, 4].

En la literatura científica reciente, esta transición tecnológica se ha bifurcado principalmente en dos grandes vertientes. Por un lado, el monitoreo de conductores se enfoca en mitigar factores conductuales directos (fatiga, somnolencia

y distracción al volante) mediante cámaras instaladas en el tablero (*dashcams*). Investigaciones recientes como [5, 6, 7, 8, 9] utilizan redes neuronales convolucionales y modelos Transformer para capturar características espaciotemporales de la fatiga, estimar variables fisiológicas (apertura ocular PERCLOS, parpadeo, rotación de la cabeza) y emitir alertas acústicas o vibratorias antes de una colisión inminente. Por otro lado, la regulación activa del tráfico urbano y la penalización automatizada de infracciones (como cruce de semáforos en rojo, invasión de carriles preferenciales o exceso de velocidad) ha migrado a sistemas inteligentes basados en cámaras de CCTV y drones [10, 11]. Estudios como [12, 13, 14] confirman la efectividad de detectores de objetos de una sola etapa (familia YOLO) y algoritmos de seguimiento de objetos múltiples (MOT) para automatizar este control de manera continua y recopilar flujos vehiculares agregados útiles en la gestión del tráfico.

Sin embargo, el despliegue de estas tecnologías en escenarios reales del mundo físico enfrenta desafíos técnicos y operativos severos que constituyen el planteamiento del problema. Primero, la variabilidad lumínica extrema (reflejos, conducción nocturna) y las oclusiones (anteojos o mascarillas en conductores; vehículos grandes bloqueando la visibilidad vial) degradan la precisión de los modelos. Segundo, las arquitecturas de deep learning más robustas conllevan una alta demanda computacional y energética, lo que dificulta su ejecución a alta velocidad y bajo consumo en hardware embebido en el borde (*Edge Computing*). Tercero, el sesgo de los conjuntos de datos, recopilados mayormente en entornos controlados, limita la generalización hacia condiciones de conducción naturalista real. Finalmente, la captura biométrica continua genera problemas de privacidad que exigen procesamiento local o aprendizaje federado. Esto define la brecha técnica entre el desempeño ideal de los modelos y las restricciones operativas reales en carretera.

Bajo este contexto, esta revisión sistemática se justifica por la necesidad de consolidar y evaluar cuantitativamente la copiosa y dispersa literatura científica publicada en el

periodo 2020–2026. Ante la irrupción exponencial de nuevos algoritmos y plataformas de hardware, este trabajo proporciona un marco de referencia que estructura el campo bajo los estándares PRISMA y PICO para identificar configuraciones metodológicas y tecnológicas idóneas según el entorno, analizando métricas paramétricas de rendimiento (precisión, mAP, FPS) y abordando las implicaciones socioeconómicas, de políticas viales y de privacidad [15, 16].

Consecuentemente, el objetivo principal es mapear y analizar estadísticamente las tendencias tecnológicas, entornos de validación y limitaciones de la visión artificial aplicada a ITS y monitoreo a partir de un corpus riguroso de 213 artículos científicos. Para guiar este análisis, planteamos responder tres preguntas de investigación: identificar las principales arquitecturas y enfoques metodológicos de IA (PI1); establecer las plataformas de hardware, software y entornos de validación predominantes (PI2); e identificar las limitaciones y retos críticos para delinear el trabajo futuro (PI3). El alcance se delimita a artículos de revistas indizadas y ponencias de congresos arbitrados publicados entre 2020 y 2026 en las bases de datos IEEE Xplore, ScienceDirect, SpringerLink y Scopus, excluyendo patentes, libros, reportes técnicos no arbitrados y trabajos puramente teóricos o sin validación empírica cuantitativa.

Finalmente, la estructura de este artículo se organiza de la siguiente manera. En la Sección II se detalla la metodología de revisión, describiendo el flujo PRISMA y el enfoque PICO. En la Sección III se presenta el análisis de resultados sobre los algoritmos, hardware y entornos experimentales. En la Sección IV se desarrolla la discusión de las implicaciones, la interpretabilidad y la adaptación de dominio. En la Sección V se examinan las limitaciones técnicas y los enfoques éticos de privacidad. Por último, en la Sección VI se exponen las conclusiones y directrices de trabajo futuro.

II. METODOLOGÍA

Para realizar este estudio de revisión sistemática, se estructuró una base de datos analítica y exhaustiva que recopila y documenta de manera detallada las características metodológicas, tecnológicas, de validación y de infraestructura de 213 artículos científicos seleccionados a partir de un proceso riguroso de búsqueda y filtrado. El objetivo de este enfoque es ofrecer una radiografía cuantitativa y cualitativa del estado de la investigación en visión artificial en el transporte.

El proceso de recolección de los artículos científicos siguió las directrices metodológicas de la declaración PRISMA (Preferred Reporting Items for Systematic Reviews and Meta-Analyses). Se realizaron búsquedas estructuradas en las principales bases de datos internacionales de mayor prestigio y relevancia para las ciencias de la computación e ingeniería, específicamente: **IEEE Xplore**, **ScienceDirect (Elsevier)**, **SpringerLink** y **Scopus**. Las cadenas de búsqueda y las respectivas bases de datos empleadas en el proceso de recolección se resumen en la Tabla I.

A través de esta estrategia de búsqueda inicial, se identificaron un total de **456 artículos** en las bases de datos

Tabla I
CADENAS DE BÚSQUEDA Y BASES DE DATOS UTILIZADAS

Base de Datos	Cadena de Búsqueda (Search Query)
IEEE Xplore	<i>“driver fatigue monitoring” AND “computer vision”</i>
ScienceDirect	<i>“computer vision” AND “traffic violation” AND “detection”</i>
Scopus	<i>“YOLO” AND “vehicle detection” AND “intelligent transportation systems”</i>
SpringerLink	<i>“driver distraction detection” AND “deep learning”</i>

mencionadas. Para depurar este conjunto y asegurar la calidad y alineación del corpus final con el alcance del estudio, se aplicaron criterios de inclusión y aceptación/exclusión secuenciales:

1. **Criterios de Inclusión:** Publicaciones revisadas por pares, escritas en inglés o español, con enfoque directo en aplicaciones de visión artificial o aprendizaje automático para ITS o monitoreo de conductores, y con fecha de publicación comprendida entre 2020 y 2026.
2. **Criterios de Aceptación/Exclusión:** Estudios que presentaran resultados experimentales empíricos detallados (con métricas cuantitativas como exactitud, precisión, mAP o FPS) y detalles claros sobre la implementación de hardware y software. Se excluyeron patentes, resúmenes de congresos sin artículo completo, y estudios basados puramente en simulaciones teóricas sin validación empírica con conjuntos de datos reales.

Tras remover duplicados entre las diferentes bases de datos y evaluar la conformidad con los criterios de inclusión y aceptación, se seleccionó un corpus final de **213 artículos** para el análisis estadístico y cualitativo detallado. El proceso detallado de selección se presenta en la Fig. 1.




Figura 1. Diagrama de Flujo del Proceso de Selección de Estudios (Declaración PRISMA).

La distribución de los 456 registros inicialmente identificados según las bases de datos de procedencia se expone en la Fig. 2, evidenciando que ScienceDirect e IEEE Xplore

representan los principales repositorios de publicaciones del área.




Figura 2. Distribución de Artículos Encontrados en la Búsqueda Inicial por Base de Datos.

II-A. Preguntas de Investigación y Enfoque PICO

Para estructurar formalmente el alcance de la revisión sistemática, se formularon los objetivos bajo el marco conceptual PICO (Población, Intervención, Comparación y Resultado/Outcome), el cual se resume en la Tabla II.

Tabla II
ESTRUCTURA DEL ENFOQUE PICO DE LA REVISIÓN

Componente PICO	Descripción
Población / Contexto	Conductores viales y flujos de tráfico en entornos urbanos y autopistas.
Intervención / Tecnología	Algoritmos de IA y Visión Computacional (Deep Learning, YOLO, CNNs, etc.).
Comparación	Enfoques metodológicos (DL, ML, Híbrido, OpenCV) y entornos (CCTV, UAV, Simulador, Vía Real).
Outcome (Resultado)	Métricas de desempeño (Accuracy, mAP), latencia (FPS) y viabilidad de despliegue (Edge Computing).

Para guiar la recopilación y el análisis cuantitativo de la literatura, se plantearon tres preguntas de investigación fundamentales:

- **PI1:** ¿Cuáles son las principales arquitecturas y enfoques metodológicos de Inteligencia Artificial y Visión por Computadora utilizados para el Monitoreo del Comportamiento de Conductores y los Sistemas de Transporte Inteligentes (ITS) en la literatura científica reciente (2020–2026)?
- **PI2:** ¿Qué entornos experimentales de prueba, plataformas de hardware de despliegue y herramientas de software de implementación predominan en la validación de estas tecnologías viales?
- **PI3:** ¿Cuáles son las limitaciones operativas, sesgos de datos y desafíos técnicos más críticos reportados por los investigadores, y qué direcciones de trabajo futuro se proponen para superarlos?

II-B. Distribución Temporal de las Publicaciones

El interés investigativo en la convergencia de la inteligencia artificial y el transporte inteligente ha mostrado una trayectoria de crecimiento significativo durante el periodo evaluado (2020–2026). Como se detalla en la Tabla III, la cantidad de publicaciones anuales experimentó un incremento sostenido, alcanzando su pico de producción científica en el periodo 2024–2025 con un total de 97 trabajos. Este dinamismo refleja la rápida adopción de nuevas arquitecturas de aprendizaje profundo y la disponibilidad de hardware de bajo costo. La Fig. 3 ilustra visualmente esta tendencia de crecimiento en el volumen de publicaciones.




Figura 3. Línea de Tendencia: Volumen Temporal de Publicaciones Científicas (2020–2026).

Tabla III
DISTRIBUCIÓN DE PUBLICACIONES ANALIZADAS POR AÑO

Año de Publicación	Cantidad de Artículos
2020	21
2021	23
2022	25
2023	35
2024	52
2025	45
2026	12

Este crecimiento exponencial se alinea con la maduración de los frameworks de programación de deep learning como PyTorch y TensorFlow, que han facilitado enormemente la experimentación y despliegue rápido de modelos de visión compleja por parte de grupos de investigación en todo el mundo.

II-C. Canales de Difusión y Venues Principales

El análisis de los canales de publicación revela un corpus altamente consolidado en publicaciones de calidad. De los 213 artículos analizados, 175 corresponden a artículos de revistas científicas de alto impacto (journals) y 38 a contribuciones presentadas en conferencias internacionales de prestigio, destacando la marcada presencia de revistas líderes en el área como *IEEE Transactions on Intelligent Transportation Systems* y *Sensors*. La concentración en estas revistas y congresos especializados subraya la solidez científica del corpus analizado.

y asegura la relevancia técnica de las tendencias estadísticas y metodológicas que se derivan de la presente revisión.

II-D. Clasificación de Enfoques de Inteligencia Artificial

Para analizar la evolución de las técnicas de IA, los artículos han sido clasificados en cuatro categorías principales basadas en la descripción de sus algoritmos:

- **Deep Learning (DL):** Trabajos fundamentados en redes neuronales convolucionales (CNN), modelos YOLO, redes de memoria a largo y corto plazo (LSTM) y arquitecturas de Transformers de visión (ViT), representando la gran mayoría de las propuestas debido a su capacidad para procesar datos no estructurados de alta dimensión.
- **Machine Learning (ML):** Algoritmos tradicionales de aprendizaje automático como máquinas de soporte vectorial (SVM), bosques aleatorios (Random Forest), K-vecinos cercanos (KNN) o modelos bayesianos.
- **Híbrido (ML + DL):** Estudios que integran representaciones de características de Deep Learning con clasificadores tradicionales de Machine Learning para optimizar el rendimiento y reducir el tiempo de entrenamiento.
- **Visión por Computadora Tradicional:** Propuestas basadas puramente en procesamiento de imágenes digital básico o descriptores geométricos mediante librerías como OpenCV tradicional sin el entrenamiento de modelos predictivos complejos.

La Tabla IV detalla la distribución cuantitativa de estos enfoques dentro del corpus.

Tabla IV
DISTRIBUCIÓN POR ENFOQUE METODOLÓGICO

Enfoque Metodológico	Cantidad de Artículos
Deep Learning (DL)	135
Otros / No especificado	44
Híbrido (ML + DL)	23
Machine Learning (ML)	11

La Fig. 4 ilustra la correlación existente entre los enfoques metodológicos adoptados y los entornos experimentales en los que se validan las soluciones. Como se aprecia, existe una clara preferencia por validar los modelos de Deep Learning en entornos de CCTV y escenarios reales de vía pública.

III. RESULTADOS

El análisis detallado del corpus literario revela las tendencias tecnológicas que definen la frontera del conocimiento en ITS y monitoreo de conductores, exponiendo una clara transición metodológica desde modelos matemáticos deterministas hacia sistemas adaptativos de redes neuronales profundas.

III-A. Dominio de Algoritmos YOLO en Tareas de Detección

Dentro del paradigma de Deep Learning, las arquitecturas de detección de objetos en una sola etapa (one-stage detectors) dominan la literatura de forma abrumadora debido a su capacidad de inferencia en tiempo real. Específicamente,




Figura 4. Preferencia de Metodologías por Entorno Experimental (Distribución porcentual).

los modelos de la familia YOLO (You Only Look Once) son la primera opción para tareas de detección en tiempo real de vehículos e infracciones. Los modelos YOLOv5 [3, 4] continúan siendo ampliamente referenciados y adaptados debido a su madurez y facilidad de entrenamiento. Para tareas de vigilancia de tráfico a gran escala, variantes optimizadas de YOLOv5 [10, 17] logran excelentes tasas de detección de camiones y motocicletas. Asimismo, estudios centrados en la compresión de modelos [18, 19] demuestran que la cuantización de pesos viabiliza su ejecución en hardware con recursos limitados.

Paralelamente, YOLOv8 [9, 18] se consolida como la arquitectura preferida para aplicaciones que demandan un alto balance entre velocidad y precisión, incorporando innovaciones como la cabeza de detección libre de anclajes (anchor-free) y una estructura de pérdida modificada. Varios investigadores han propuesto mejoras a la capa de atención de YOLOv8 [20, 21] para mitigar la tasa de falsos negativos en condiciones de lluvia o niebla. Otros trabajos [22, 23] integran YOLOv8 con estimadores de velocidad basados en flujo óptico. Asimismo, versiones más recientes e híbridas como YOLOv7 [5, 24], YOLOv9 [25], YOLOv10 y YOLOv11 demuestran innovaciones en términos de eficiencia de parámetros y atención multiescala, permitiendo capturar vehículos a gran distancia en tomas de alta resolución espacial.

Asimismo, investigaciones muy recientes comienzan a explorar la transición desde detectores de objetos basados puramente en convoluciones hacia arquitecturas basadas en Transformers de tiempo real, tales como RT-DETR [17, 18]. Estos modelos eliminan la necesidad del procesamiento posterior de Supresión No Máxima (NMS, por sus siglas en inglés), el cual suele representar un cuello de botella de latencia crítico en sistemas embebidos de tráfico cuando la densidad de vehículos es extremadamente alta [26, 20]. Al procesar las relaciones espaciales mediante auto-atención multi-escala directa de manera paralela, RT-DETR y sus variantes híbridas prometen un rendimiento de detección más estable frente a oclusiones mutuas de vehículos en autopistas saturadas,

abriendo una nueva línea de optimización para los sistemas inteligentes de transporte de próxima generación.

III-B. Redes Neuronales Convolucionales y Modelos Temporales

Las redes convolucionales clásicas (CNN) [5, 12] se mantienen como la base estructurante para el análisis de fatiga y la clasificación fina de expresiones faciales a través de marcas faciales. Para robustecer la detección frente a cambios rápidos en la pose de la cabeza, se proponen redes CNN multirrama [14, 2] y modelos basados en MobileNet [4, 10] optimizados para bajo consumo energético.

Para la modelación temporal de secuencias de video (por ejemplo, el análisis continuo del comportamiento o de colisiones a lo largo del tiempo), los autores recurren a redes recurrentes y LSTM [1, 2]. Las arquitecturas combinadas CNN-LSTM [24, 27] permiten capturar transiciones dinámicas como el pestañeo lento o el cabeceo del conductor. Otros desarrollos [28, 29] aplican redes de memoria para la predicción de trayectorias vehiculares en cruces urbanos. Por último, la irrupción de los Vision Transformers (ViT) y mecanismos de auto-atención [1, 26] marca un cambio tecnológico relevante, permitiendo capturar relaciones espaciotemporales de largo alcance con mayor precisión. Modelos espaciotemporales basados en atención [30, 24] y transformers de escala temporal [31, 32] se posicionan como alternativas altamente precisas aunque computacionalmente costosas.

III-C. Enfoques de Machine Learning y Arquitecturas Híbridas

A pesar del dominio del aprendizaje profundo, los algoritmos tradicionales de Machine Learning mantienen un rol importante en el estado del arte. Los modelos SVM [6, 2] y Random Forest [33, 34] se emplean comúnmente para la clasificación final de datos tabulares provenientes de sensores a bordo del vehículo o variables fisiológicas directas. Adicionalmente, clasificadores tradicionales [18, 35] y modelos basados en árboles [36, 37] ofrecen una alta interpretabilidad requerida para sistemas de seguridad activa críticos.

Adicionalmente, las arquitecturas híbridas [2, 18] combinan el poder de representación de características de Deep Learning (usando CNNs como extractores automáticos de características de alto nivel) con la robustez estadística de los clasificadores ML tradicionales para reducir la latencia de inferencia y optimizar el rendimiento en hardware de borde con recursos limitados. Propuestas basadas en la extracción híbrida [38, 39] reducen el tiempo de entrenamiento sin sacrificar precisión. Por su parte, los enfoques tradicionales de visión por computadora se aplican en la etapa de preprocesamiento, como la normalización del contraste y la segmentación básica de regiones de interés (ROI) mediante umbralización y descriptores geométricos básicos.

III-D. Entornos Experimentales de Prueba y Despliegue de Hardware

Los entornos experimentales reportados en la literatura científica para validar estas soluciones inteligentes se clasifican en cuatro áreas principales:

1. **Cámaras de Videovigilancia (CCTV):** Utilizadas principalmente para el monitoreo pasivo de intersecciones urbanas, detección de infracciones y detección automática de colisiones [14, 1].
2. **Cámaras A bordo / Conducción Naturalista:** Conducción en vehículos reales o simuladores con cámaras de cabina [5, 13].
3. **Imágenes Aéreas (UAV / Drones):** Toma aérea de tráfico y trayectorias [3, 11].
4. **Simuladores de Conducción / Entornos Virtuales:** Simuladores en PC o cabinas virtuales [6, 12].

Para profundizar en las relaciones entre el entorno experimental y las librerías o hardware utilizados, la Fig. 5 ilustra la concentración de trabajos mediante un mapa de calor coincidente de frecuencias. Como se observa, existe una fuerte dependencia del uso de librerías como OpenCV o MediaPipe aplicadas sobre entornos reales y CCTV [2, 8], mientras que el hardware de borde especializado como las GPUs NVIDIA Jetson y Raspberry Pi representan los principales habilitadores para implementar estos sistemas directamente en vehículos reales y UAV [40, 41].




Figura 5. Mapa de Calor Cruzado: Entorno Experimental vs. Plataforma de Implementación de Software y Hardware.

III-E. Evaluación del Rendimiento y Métricas Comparativas

La evaluación del rendimiento de los modelos en la literatura científica se basa en métricas de clasificación y regresión bien establecidas en visión por computadora. Entre las principales se encuentran la exactitud (Accuracy), la precisión (Precision), la sensibilidad (Recall), el puntaje F1 (F1-Score) y la precisión media promedio (mAP). Las fórmulas que gobiernan estas métricas principales se definen de la siguiente manera:




Figura 6. Plataformas de Implementación vs. Enfoque Metodológico de la Investigación.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (1)$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (3)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

donde TP representa los verdaderos positivos, TN los verdaderos negativos, FP los falsos positivos y FN los falsos negativos. Para evaluar cuantitativamente el desempeño de estas soluciones en base a la literatura que reporta métricas numéricas concretas, la Fig. 7 expone mediante diagramas de caja y bigotes la distribución del rendimiento (*accuracy*) reportado según el enfoque metodológico de IA empleado. Este análisis comparativo consolida visualmente la efectividad del aprendizaje profundo en contraste con otras aproximaciones estadísticas o híbridas [40, 19].




Figura 7. Comparativa de la Distribución de Exactitud (Accuracy %) según el Enfoque Metodológico de IA.

III-F. Tabulación de Investigaciones Destacadas

Las Tablas de la V a la VIII y de la IX a la XIII presentan el compendio total de las investigaciones analizadas en esta revisión sistemática, detallando la metodología de IA, el entorno experimental y las métricas de rendimiento de cada trabajo.

III-G. Respuestas a las Preguntas de Investigación

A partir del análisis cuantitativo y cualitativo llevado a cabo en esta revisión, se da respuesta formal a las preguntas de investigación planteadas en la metodología:

- **Respuesta a la PI1 (Paradigmas Tecnológicos):** Se evidencia una hegemonía del Aprendizaje Profundo (Deep Learning), representando el 72.3 % del corpus analizado (135 trabajos). Las arquitecturas de una sola etapa (particularmente la familia YOLO) dominan las tareas de detección de infracciones y objetos viales, mientras que las redes convolucionales combinadas con modelos temporales (LSTM y Transformers) prevalecen en el monitoreo de fatiga y distracción debido a su capacidad para procesar dependencias espaciotemporales de video.
- **Respuesta a la PI2 (Entornos y Despliegue):** Aunque la mayoría de los estudios no detallan su entorno experimental en la base de datos de origen, entre aquellos que sí lo especifican destacan los sistemas de videovigilancia CCTV (30 artículos) y las tecnologías aéreas basadas en drones/UAV (18 artículos) para la gestión de tráfico urbano. La validación para monitoreo de conductores se realiza mayoritariamente en entornos reales de conducción naturalista (18 artículos) y simuladores virtuales (15 artículos). El despliegue de hardware está liderado por dispositivos en el borde como NVIDIA Jetson y Raspberry Pi, implementados mediante librerías OpenCV y MediaPipe.
- **Respuesta a la PI3 (Desafíos y Direcciones Futuras):** Las limitaciones más recurrentes reportadas por los investigadores se centran en la alta sensibilidad de los modelos a variaciones de iluminación extrema (conducción nocturna, deslumbramiento) y oclusiones físicas. Adicionalmente, el resguardo de la privacidad del conductor representa un reto regulatorio crítico. El trabajo futuro en el área apunta al uso de Inteligencia Artificial Explicable (XAI), técnicas de Adaptación de Dominio No Supervisada (UDA), Aprendizaje Federado y fusión multimodal de sensores.

IV. DISCUSIÓN

A partir de la tabulación sistemática y las tendencias estadísticas obtenidas del corpus, resulta de gran interés contrastar cualitativamente las implicaciones prácticas de los modelos en seguridad vial y control de tránsito.

IV-A. Implicaciones del Monitoreo de Conductores y Tránsito

En la categoría de monitoreo de conductores, la precisión de la detección de fatiga y expresiones de somnolencia se ha visto

Tabla V
RESUMEN DE INVESTIGACIONES EN MONITOREO DE CONDUCTORES Y MÉTRICAS DE RENDIMIENTO (PARTE 1)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[5]	Research on the Analysis and Recognition System for Dangerous Driving Behaviors Based o...	YOLOv11, CNN (Redes Convolucion...	Conducción naturalista / Vehícul...	mAP50 of 69.26, accuracy of 65.5...
[6]	Driving Behavior Classification and Risk Quantification via Multisensor Machine Learnin...	SVM, Machine Learning	Simulador de conducción / Entorn...	92 % accuracy, 88 % accuracy
[7]	Trustworthy Driver State Perception via Contextual Interaction-Driven Evidential Vision...	Deep Learning	No especificado	No especificado
[12]	Driver Monitoring System Using Computer Vision for Real-Time Detection of Fatigue, Dist...	CNN (Redes Convolucionales), Mob...	Simulador de conducción / Entorn...	100 % accuracy
[13]	A Cost-Effective Intelligent Edge-Based Driver Monitoring System for Real-Time Detectio...	No especificado	Conducción naturalista / Vehícul...	No especificado
[10]	Advancing Road Safety: A Comprehensive Evaluation of Object Detection Models for Commer...	YOLOv5, Faster R-CNN, RetinaNet,...	No especificado	No especificado
[11]	Evaluating Defensive Driving Behaviour Based on Safe Distance Between Vehicles: A Case ...	No especificado	UAV / Drones	No especificado
[15]	Unsupervised Learning Approach for Risky Driving Behavior Identification on Expressways...	CNN (Redes Convolucionales), Aut...	No especificado	No especificado
[16]	Visual Risk-Aware Decision-Making Method for Autonomous Driving	Reinforcement Learning	Simulador de conducción / Entorn...	No especificado
[18]	Real-Time Driver Drowsiness Detection Using Facial Analysis and Machine Learning Techni...	YOLOv8, YOLOv5, Faster R-CNN, CN...	No especificado	100 % precision, accuracy of 98.8...
[26]	Dangerous Driving Behavior Detection Based on Computer Vision	CNN (Redes Convolucionales), Tra...	No especificado	No especificado
[20]	Utilization of YoloV8 Algorithm for in-Vehicle Video-Based Driver Monitoring System	YOLOv8	No especificado	89.6 % precision, 87.2 % recall, 8...
[40]	Enhancing Driving Safety Evaluation Through Correlation Analysis of Driver Behavior	No especificado	Conducción naturalista / Vehícul...	No especificado
[42]	Enhancing convolutional neural networks in electroencephalogram driver drowsiness detec...	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[25]	YOLO-ACE: A Vehicle and Pedestrian Detection Algorithm for Autonomous Driving Scenarios...	YOLOv10, YOLO	No especificado	70.9 FPS
[43]	Integrated deep learning framework for driver distraction detection and real-time road ...	YOLO, CNN (Redes Convolucionales...	No especificado	25 frames per second
[33]	Abnormal Driving Behavior Detection: A Machine and Deep Learning Based Hybrid Model	Random Forest, ResNet, Efficient...	No especificado	accuracy of 99.3
[44]	Classification of Driver Behaviour Using External Observation Techniques for Autonomous...	YOLO	No especificado	No especificado
[45]	Modeling of injury severity of distracted driving accident using statistical and machin...	XGBoost, Machine Learning	No especificado	No especificado
[46]	Risk Assessment Method for Autonomous Vehicles Violating Safety Common Sense Based on D...	GMM	No especificado	No especificado
[41]	Composite Safety Potential Field for Highway Driving Risk Assessment	No especificado	Conducción naturalista / Vehícul...	No especificado
[47]	A multi-class driver behavior dataset for real-time detection and road safety enhancement	No especificado	No especificado	No especificado
[48]	Deep Learning Model for Driver Behavior Detection in Cyber-Physical System-Based Intell...	Deep Learning	No especificado	94 % accuracy
[49]	Design and implementation of a driving safety assistant system based on driver behavior	No especificado	No especificado	No especificado

Tabla VI
RESUMEN DE INVESTIGACIONES EN MONITOREO DE CONDUCTORES Y MÉTRICAS DE RENDIMIENTO (PARTE 2)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[50]	Integrating visual large language model and reasoning chain for driver behavior analysi...	No especificado	No especificado	No especificado
[51]	Nonintrusive Driving Behavior Characterization From Road-Side Cameras	Deep Learning	Videovigilancia / CCTV	650 ms
[52]	Validation and Analysis of Driving Safety Assessment Metrics in Real-world Car-Followin...	No especificado	Conducción naturalista / Vehícul...	No especificado
[53]	Assessing the driving behaviour of motorcyclists to improve road safety	No especificado	No especificado	No especificado
[34]	Detection of distracted driving through the analysis of real-time driver, vehicle, and ...	Random Forest	Simulador de conduc- ción / Entorn...	No especificado
[54]	Passive Monitoring of Dangerous Driving Behaviors Using mm-Wave Radar	CNN (Redes Convolu- cionales)	No especificado	No especificado
[55]	Safety Driving Detection Based on Convolution Neural Network	YOLOv5, Deep Lear- ning	No especificado	No especificado
[56]	Augmented Recognition of Distracted Driving State Based on Electrophysiological Analysi...	XGBoost, Machine Learning	Simulador de conduc- ción / Entorn...	accuracy of 95.1
[35]	Driving Attention State Detection Based on GRU-EEGNet	SVM, Deep Learning	No especificado	No especificado
[57]	On investigating drivers' attention allocation during partially-automated driving	No especificado	Simulador de conduc- ción / Entorn...	No especificado
[58]	The role of driver head pose dynamics and instantaneous driving in safety critical even...	No especificado	Conducción naturalista / Vehícul...	No especificado
[59]	Enhancing Road Safety: A Driver Fatigue Detection and Beha- viour Monitoring System using...	No especificado	No especificado	No especificado
[60]	Realization of a Safe Driving Monitoring System for Motor Vehicles	No especificado	No especificado	No especificado
[61]	YOLO-SGC: A Dangerous Driving Behavior Detection Method With Multiscale Spatial-Channel...	YOLOv8, YOLO	No especificado	No especificado
[62]	Comprehensive study of driver behavior monitoring systems using computer vision and mac...	Machine Learning	No especificado	No especificado
[63]	A Study on the Effectiveness of GPT-4V in Classifying Driver Behavior Captured on Video...	No especificado	No especificado	98.9 % accuracy, 98.4 % accuracy, ...
[64]	Audiovisual presentation of variable message signs improves message processing in distr...	No especificado	No especificado	No especificado
[65]	Prediction of Drivers' Red-Light Running Behaviour in Connected Vehicle Environments Us...	LSTM	Conducción naturalista / Vehícul...	No especificado
[66]	An Enhanced Deep Neural Network Model for the Detection of Anomalous Behavior of Driver...	YOLOv3, ResNet, Mo- bileNet, Deep ...	No especificado	accuracy of 95
[67]	Driver Drowsiness Detection Based on Convolutional Neural Network Architecture Optimiza...	CNN (Redes Convolu- cionales)	No especificado	No especificado
[68]	Real-time driver drowsiness and distraction detection using con- volutional neural networ...	CNN (Redes Convolu- cionales)	Conducción naturalista / Vehícul...	No especificado
[69]	Wrong-Way Driving Detection for Enhanced Road Safety using Computer Vision and Machine ...	YOLOv4, Deep Lear- ning, Machine L...	No especificado	No especificado
[70]	Detection of Distracted Driver Using Convolutional Neural Net- work	CNN (Redes Convolu- cionales), Res...	No especificado	No especificado
[71]	Identifying risky driving behavior: a field study using instrumented vehicles	No especificado	No especificado	No especificado

Tabla VII
RESUMEN DE INVESTIGACIONES EN MONITOREO DE CONDUCTORES Y MÉTRICAS DE RENDIMIENTO (PARTE 3)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[72]	European NCAP Driver State Monitoring Protocols: Prevalence of Distraction in Naturalis...	No especificado	Conducción naturalista / Vehícul...	No especificado
[73]	Evaluation of intersection crashes using naturalistic driving data through the lens of ...	No especificado	Conducción naturalista / Vehícul...	No especificado
[74]	Driver distraction and in-vehicle interventions: A driving simulator study on visual at...	No especificado	Simulador de conducción / Entorn...	No especificado
[36]	Young Novice Drivers' Cognitive Distraction Detection: Comparing Support Vector Machine...	SVM, Random Forest	Simulador de conducción / Entorn...	No especificado
[75]	Real-time driving risk assessment based on the psycho-physical field	No especificado	Conducción naturalista / Vehícul...	No especificado
[76]	RFDANet: an FMCW and TOF radar fusion approach for driver activity recognition using mu...	CNN (Redes Convolucionales), LST...	No especificado	accuracy of 94.5
[77]	A Deep-Learning Approach to Driver Drowsiness Detection	CNN (Redes Convolucionales)	No especificado	No especificado
[78]	Detection of Drowsiness among Drivers Using Novel Deep Convolutional Neural Network Model	CNN (Redes Convolucionales), Dee...	No especificado	accuracy of 96.69
[79]	Vision-Language Models Can Identify Distracted Driver Behavior From Naturalistic Videos	No especificado	Conducción naturalista / Vehícul...	No especificado
[80]	Detection of Unsafe Driving and Drivers Behaviour Monitoring System	Machine Learning	No especificado	No especificado
[81]	Real-Time Deep Learning-Based Drowsiness Detection: Leveraging Computer-Vision and Eye-...	Deep Learning	No especificado	95.8 % accuracy
[82]	Modeling driver behavior in critical traffic scenarios for the safety assessment of aut...	No especificado	Simulador de conducción / Entorn...	No especificado
[83]	Enhancing Road Safety Through Accurate Detection of Hazardous Driving Behaviors With Gr...	No especificado	No especificado	accuracy of 97.5, accuracy of 98.1
[84]	Risk Assessment of Distracted Driving Behavior Based on Visual Stability Coefficient	No especificado	Simulador de conducción / Entorn...	No especificado
[85]	Unusual Driver Behavior Detection in Videos Using Deep Learning Models	CNN (Redes Convolucionales), Res...	No especificado	No especificado
[86]	Potential risk assessment for safe driving of autonomous vehicles under occluded vision	No especificado	No especificado	No especificado
[87]	Improving EEG-Based Driver Distraction Classification Using Brain Connectivity Estimators	SVM	Simulador de conducción / Entorn...	No especificado
[88]	Detecting Driver Cognition Alertness State From Visual Activities in Normal and Emergen...	Deep Learning	No especificado	No especificado
[89]	An Autonomous Framework for Real-Time Wrong-Way Driving Vehicle Detection from Closed-C...	Deep Learning	Videovigilancia / CCTV	95.23 % accuracy
[90]	DDNet- A Deep Learning Approach to Detect Driver Distraction and Drowsiness	CNN (Redes Convolucionales), Dee...	No especificado	99.95 % accuracy
[91]	Attention-based deep neural network for driver behavior recognition	No especificado	No especificado	accuracy of 98.48
[92]	A computer vision-based deep learning model to detect wrong-way driving using pan-tilt-...	Deep Learning	Videovigilancia / CCTV	No especificado
[93]	A smart analysis of driver fatigue and drowsiness detection using convolutional neural ...	CNN (Redes Convolucionales), Res...	No especificado	93.69 % accuracy
[94]	Intelligent Detection of Vehicle Driving Safety Based on Deep Learning	YOLO, SSD, CNN (Redes Convolutio...	No especificado	79.6 % accuracy, 99.96 % accuracy,...

Tabla VIII
RESUMEN DE INVESTIGACIONES EN MONITOREO DE CONDUCTORES Y MÉTRICAS DE RENDIMIENTO (PARTE 4)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[37]	Driver Fatigue and Distracted Driving Detection Using Random Forest and Convolutional N...	CNN (Redes Convolucionales), Ran...	No especificado	No especificado
[95]	Automatic driver distraction detection using deep convolutional neural networks	CNN (Redes Convolucionales), Mob...	No especificado	No especificado
[96]	Cars and distraction: How to address the limits of Driver Monitoring Systems and improv...	No especificado	No especificado	No especificado
[97]	Understanding Driving Distractions: A Multimodal Analysis on Distraction Characterization	No especificado	No especificado	No especificado
[98]	Cognitive Distraction State Recognition of Drivers at a Nonsignalized Intersection in a...	LSTM, Bi-LSTM, SVM	No especificado	No especificado
[99]	Risky Driving Behavior Recognition Based on Vehicle Trajectory	No especificado	UAV / Drones	No especificado
[100]	Driver behaviour detection using 1D convolutional neural networks	CNN (Redes Convolucionales)	No especificado	accuracy of 99.999
[101]	Assessment of the Influence of Technology-Based Distracted Driving on Drivers' Infrastruct...	No especificado	No especificado	No especificado
[102]	Machine Learning Techniques to Identify Unsafe Driving Behavior by Means of In-Vehicle ...	SVM, Machine Learning	No especificado	No especificado
[103]	Real-Time Driving Distraction Recognition Through a Wrist-Mounted Accelerometer	CNN (Redes Convolucionales), LSTM	Simulador de conducción / Entorn...	No especificado
[104]	Research on Safe Driving Evaluation Method Based on Machine Vision and Long Short-Term ...	SSD, CNN (Redes Convolucionales)...	No especificado	No especificado
[105]	The Improvement of Road Driving Safety Guided by Visual Inattention Blindness	No especificado	No especificado	No especificado
[106]	Identification of Driving Safety Profiles in Vehicle to Vehicle Communication System Ba...	No especificado	No especificado	90 % accuracy
[107]	A deep neural network approach for detecting wrong-way driving incidents on highway roads	YOLOv5, Deep Learning	Videovigilancia / CCTV	No especificado
[108]	Research on a Cognitive Distraction Recognition Model for Intelligent Driving Systems B...	LSTM, Bi-LSTM, SVM	Conducción naturalista / Vehícul...	No especificado
[109]	Study on drivers' visual perception characteristics during the takeover of vehicle con...	No especificado	Simulador de conducción / Entorn...	No especificado
[110]	The Influence of Visual-Manual Distractions on Anticipatory Driving	No especificado	Simulador de conducción / Entorn...	No especificado
[111]	Improving Machine Learning Identification of Unsafe Driver Behavior by Means of Sensor ...	SVM, Machine Learning	No especificado	accuracy of 88
[112]	Driver distraction by digital billboards? Structural equation modeling based on natural...	No especificado	Conducción naturalista / Vehícul...	No especificado
[113]	Driver behavior detection and classification using deep convolutional neural networks	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[114]	HCF: A Hybrid CNN Framework for Behavior Detection of Distracted Drivers	CNN (Redes Convolucionales), Res...	No especificado	accuracy of 96.74
[115]	Deep CNN-Based Real-Time Traffic Light Detector for Self-Driving Vehicles	CNN (Redes Convolucionales), Dee...	Conducción naturalista / Vehícul...	accuracy of 99.3

Tabla IX
RESUMEN DE INVESTIGACIONES EN DETECCIÓN DE INFRACCIONES Y ACCIDENTES DE TRÁNSITO (PARTE 1)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[14]	SafeStreets: Deep Learning-Based Real-Time Traffic Violation Detection System	CNN (Redes Convolucionales), Dee...	Videovigilancia / CCTV	No especificado
[1]	Intelligent Traffic Accident Detection System using Deep Learning Fusion Techniques	LSTM, Transformer, ResNet, Deep ...	Videovigilancia / CCTV	accuracy of 97.93
[2]	A Comparative Evaluation of Deep Learning Models for Road Accident Detection Using CCTV...	CNN (Redes Convolucionales), LST...	Videovigilancia / CCTV	99 % accuracy, 99.53 % accuracy
[3]	UAV-based object detection model for smart surveillance using deep neural network	YOLOv5	UAV / Drones	95.1 % precision, 86.3 % recall
[4]	Hybrid Deep Learning and Classification Framework for Automatic Traffic Inspection Clas...	YOLOv5, CNN (Redes Convocional...	No especificado	No especificado
[8]	Traffic Violations Control Using Deep Learning	Deep Learning	Videovigilancia / CCTV	accuracy of 0.927
[9]	AI-Powered Traffic Violation Detection System Using CCTV, and Deep Learning	YOLOv8, Deep Learning	Videovigilancia / CCTV	accuracy of 88.4, 28 FPS, 180 ms
[17]	Computer Vision-Based Traffic Monitoring: Design of a Red-Light Violation Detection Sys...	YOLOv5, Deep Learning	No especificado	95 % accuracy
[19]	Traffic Incident Detection Algorithm based on Deep Learning: A Statistical Optimization...	YOLOv5, Deep Learning	No especificado	No especificado
[21]	Red-light Running Detection	YOLOv8, YOLO, CNN (Redes Convolu...	Videovigilancia / CCTV	89.2 % precision, 92.6 % recall
[22]	Red Light Running Detection Using AI-Powered Object Tracking on Embedded Systems	YOLOv8, CNN (Redes Convolucionales)	No especificado	29 fps
[23]	DSR-YOLO: A Lightweight and Efficient YOLOv8 Model for Enhanced Pedestrian Detection	YOLOv8, YOLO	No especificado	No especificado
[116]	Drone-assisted adaptive object detection and privacy-preserving surveillance in smart c...	Reinforcement Learning	UAV / Drones	No especificado
[117]	Computer-vision based automatic rider helmet violation detection and vehicle identifica...	YOLOv8, CNN (Redes Convocional...	No especificado	accuracy of 98.56
[118]	GY-YOLO: ghost separable YOLO for pedestrian detection	YOLOv8, YOLOv5, YOLO	Videovigilancia / CCTV	92.8 % mAp, 90.3 % mAp, 91.1 % mAp
[119]	Deep Learning-based Multiple Pedestrian Crossing Behavior Analysis Framework	YOLO, CNN (Redes Convolucionales...	No especificado	No especificado
[120]	Deep Learning based enhanced aerial object detection	Deep Learning	UAV / Drones	No especificado
[121]	Real-time Identification of Traffic Violations through Deep Learning Techniques	Deep Learning	No especificado	accuracy of 95.8
[30]	D-TLDDetector: Advancing Traffic Light Detection With a Lightweight Deep Learning Model	Transformer, Vision Transformer ...	No especificado	98.23 % accuracy, 135 FPS
[24]	Integrated neural network framework for multi-object detection and recognition using UA...	YOLOv11, LSTM, Autoencoder, Tran...	UAV / Drones	accuracy of 97.8, accuracy of 96...
[38]	Integration of deep learning algorithms for real-time vehicle accident detection from s...	CNN (Redes Convolucionales), Res...	Videovigilancia / CCTV	accuracy of 98
[122]	Towards Safer Roads: An End-to-End Deep Learning Framework for Traffic Violation Detect...	YOLOv8, Deep Learning	No especificado	No especificado
[123]	Traffic Detection and Traffic Violation Detection using Deep Learning: An End-to-End YO...	YOLO, Deep Learning	Videovigilancia / CCTV	No especificado
[124]	LC-YOLO: An Improved YOLOv8-Based Lane Detection Model for Enhanced Lane Intrusion Dete...	YOLOv8, YOLO, Deep Learning	No especificado	97.9 % mAP, mAP of 97.9

Tabla X
RESUMEN DE INVESTIGACIONES EN DETECCIÓN DE INFRACCIONES Y ACCIDENTES DE TRÁNSITO (PARTE 2)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[125]	Deep Learning-based Traffic Violation Detection using YOLOv8 and PaddleOCR	YOLOv8, Deep Learning	No especificado	No especificado
[39]	Traffic Violation Detection Using Deep Learning	YOLO, CNN (Redes Convolucionales...	No especificado	No especificado
[126]	Red light crossing violations modelling using deep learning and variance-based sensitiv...	Deep Learning	No especificado	No especificado
[127]	UrbanEye: Deep Learning Enhanced Two-Wheeler Traffic Rule Violation Detection using YOL...	YOLO, Deep Learning	No especificado	No especificado
[128]	Traffic Signal Violation Detection System	SSD, CNN (Redes Convolucionales)...	No especificado	No especificado
[129]	Real-Time Traffic Violation Detection with Automated Enforcement Using Computer Vision	YOLOv5, Mask R-CNN, CNN (Redes C...	No especificado	No especificado
[27]	Data-Driven Anomaly Detection in Urban Traffic Data: A Deep Learning Approach	LSTM, Autoencoder, Deep Learning	No especificado	No especificado
[130]	Application and Optimization of Convolutional Neural Networks Based on Deep Learning in...	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[31]	The Smart City Transportation: Deep Learning Ensemble Approach for Traffic Accident Det...	CNN (Redes Convolucionales), Tra...	Videovigilancia / CCTV	No especificado
[131]	Detection of Unusual Activities on the Road Using Deep CNN	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[28]	A multimodal deep fusion framework for highway traffic anomaly detection	LSTM	No especificado	accuracy of 0.980, F1 score of 0...
[132]	Detection of Unsafe Behavior in conveying Vehicle Parts using Computer Vision	YOLOv8, CNN (Redes Convocional...	Entorno industrial / Laboral	No especificado
[133]	Unsafe-Net: YOLO v4 and ConvLSTM based computer vision system for real-time detection o...	YOLO, Deep Learning	Entorno industrial / Laboral	No especificado
[134]	Intelligent Vehicle Violation Detection System Under Human-Computer Interaction and Com...	No especificado	No especificado	96.86 % accuracy
[135]	IoT Network Traffic Analysis with Deep Learning	Deep Learning, Machine Learning	No especificado	98 % accuracy
[136]	Automated Detection of Traffic Rule Violation using Deep Learning Techniques	YOLOv5, Deep Learning	No especificado	accuracy of 90
[137]	Improved Object Detection in UAV Images using Deep Learning	YOLOv5, Deep Learning	UAV / Drones	No especificado
[138]	History-Based Road Traffic Anomaly Detection Using Deep Learning and Real-World Data	Deep Learning	No especificado	No especificado
[29]	Real-Time Detection of Network Traffic Anomalies in Big Data Environments Using Deep Le...	CNN (Redes Convolucionales), LST...	No especificado	No especificado
[139]	Putting ChatGPT vision (GPT-4V) to the test: risk perception in traffic images	No especificado	No especificado	No especificado
[140]	Traffic Rules Violation Detection System using YOLO v8 Model	YOLO, CNN (Redes Convolucionales)	No especificado	No especificado
[141]	Dense Pedestrian Detection Based on GR-YOLO	YOLOv8, YOLO, Deep Learning	No especificado	No especificado
[142]	Traffic Signal Violation Detection System Using Computer Vision	YOLOv8, Deep Learning	Videovigilancia / CCTV	No especificado
[143]	Enhancing vehicle detection in intelligent transportation systems via autonomous UAV pl...	YOLOv8	UAV / Drones	No especificado

Tabla XI
RESUMEN DE INVESTIGACIONES EN DETECCIÓN DE INFRACCIONES Y ACCIDENTES DE TRÁNSITO (PARTE 3)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[32]	Transformer-Based Spatio-Temporal Unsupervised Traffic Anomaly Detection in Aerial Videos	Transformer, Machine Learning	UAV / Drones	No especificado
[144]	Convolutional Neural Network and LSTM for Seat Belt Detection in Vehicles using YOLO3	CNN (Redes Convolucionales), LST...	Videovigilancia / CCTV	89 % accuracy, accuracy of 89
[145]	Enforcing Traffic Safety: A Deep Learning Approach for Detecting Motorcyclists' Helmet ...	YOLOv8, Deep Learning	No especificado	F1 score of 0.91, F1 score of 0.96
[146]	Detection of Traffic Violation and Vehicle Number Plate Using Computer Vision	Deep Learning	No especificado	No especificado
[147]	PVswin-YOLOv8s: UAV-Based Pedestrian and Vehicle Detection for Traffic Management in Sm...	YOLOv8, YOLOv5, YOLOv3, YOLO, Re...	UAV / Drones	No especificado
[148]	Grand challenge of image processing in automatic detection of vehicles running in red l...	No especificado	No especificado	No especificado
[149]	Deep Learning-Based Anomaly Detection in Network Traffic for Cyber Threat Identification	CNN (Redes Convolucionales), Aut...	No especificado	95 % accuracy
[150]	Development of a Deep Learning-Based System for Road Traffic Anomaly Detection	CNN (Redes Convolucionales), Dee...	No especificado	100 % accuracy, accuracy of 100
[151]	A computer vision system for detecting motorcycle violations in pedestrian zones	YOLOv8, SSD, MobileNet, Deep Lea...	Videovigilancia / CCTV	No especificado
[152]	VANET Network Traffic Anomaly Detection Using GRU-Based Deep Learning Model	Deep Learning	No especificado	No especificado
[153]	A Vision-Based System: Detecting Traffic Law Violation Case Study of Red-Light Running ...	YOLOv8, Machine Learning	No especificado	No especificado
[154]	Optimal deep learning based object detection for pedestrian and anomaly recognition model	YOLOv5, CNN (Redes Convolucionales)...	No especificado	AUC score of 99.05
[155]	A deep learning-based car accident detection approach in video-based traffic surveillance	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[156]	A Self-Adaptive Automatic Incident Detection System for Road Surveillance Based on Deep...	Deep Learning	No especificado	accuracy of 2
[157]	Improving Traffic Surveillance: Deep Learning Approach for Road Anomaly Detection in Vi...	CNN (Redes Convolucionales), Dee...	Videovigilancia / CCTV	No especificado
[158]	Intelligent vehicle pedestrian light (IVPL): A deep reinforcement learning approach for...	Reinforcement Learning	No especificado	No especificado
[159]	Pedestrian Red-Light Violation Detection Based on Deep Learning Vision	YOLOv5, Deep Learning	No especificado	No especificado
[160]	Automated detection of vehicles with anomalous trajectories in traffic surveillance videos	Deep Learning	Videovigilancia / CCTV	No especificado
[161]	Research on Anomaly Network Detection Based on Self-Attention Mechanism	LSTM, XGBoost, Machine Learning	No especificado	No especificado
[162]	Real-Time Event-Driven Road Traffic Monitoring System Using CCTV Video Analytics	CNN (Redes Convolucionales)	Videovigilancia / CCTV	accuracy of 82.3
[163]	Deep learning-based anomaly detection for individual drone vehicles performing swarm mi...	Deep Learning	UAV / Drones	No especificado
[164]	Method For Traffic Violation Detection Using Deep Learning	YOLOv8, CNN (Redes Convolucionales)...	Videovigilancia / CCTV	No especificado
[165]	An End-to-End Online Traffic-Risk Incident Prediction in First-Person Dash Camera Videos	No especificado	No especificado	9.60 fps, 1.44 fps
[166]	A Context-Aware, Computer-Vision-Based Approach for the Detection of Taxi Street-Hailin...	No especificado	Entorno industrial / Laboral	80 % accuracy, 84 % precision, 84 %...

Tabla XII
RESUMEN DE INVESTIGACIONES EN DETECCIÓN DE INFRACCIONES Y ACCIDENTES DE TRÁNSITO (PARTE 4)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[167]	Robust real-time traffic light detector on small-form platform for autonomous vehicles	CNN (Redes Convolucionales), Mac...	No especificado	93.42 % accuracy, 30.01 Frames Pe...
[168]	Detection of traffic rule violation in University campus using deep learning model	YOLO, Deep Learning	Videovigilancia / CCTV	No especificado
[169]	Network Anomaly Intrusion Detection Based on Deep Learning Approach	CNN (Redes Convolucionales), LST...	No especificado	No especificado
[170]	Traffic Congestion Detection from Surveillance Videos using Deep Learning	CNN (Redes Convolucionales), Dee...	Videovigilancia / CCTV	No especificado
[171]	Smart City Transportation: Deep Learning Ensemble Approach for Traffic Accident Detection	Deep Learning	No especificado	No especificado
[172]	Traffic Signal Violation Detection Through Computer Vision	Deep Learning	No especificado	No especificado
[173]	A data-driven approach for road accident detection in surveillance videos	CNN (Redes Convolucionales), Res...	Simulador de conducción / Entorn...	No especificado
[174]	Predicting perceived risk of traffic scenes using computer vision	No especificado	No especificado	No especificado
[175]	Real-Time Vehicle Accident Recognition from Traffic Video Surveillance using YOLOV8 and...	YOLOv8	No especificado	93.8 % precision, 98 % recall, 96....
[176]	A Real-Time Computer Vision Based Approach to Detection and Classification of Traffic I...	YOLOv5, ResNet	No especificado	mAP of 83.3
[177]	Deep Learning applied to Road Accident Detection with Transfer Learning and Synthetic I...	Deep Learning	No especificado	No especificado
[178]	Deep learning for autonomous vehicle and pedestrian interaction safety	CNN (Redes Convolucionales), Dee...	No especificado	accuracy of 81.98
[179]	Machine Learning Based Approach for Traffic Rule Violation Detection	YOLOv3, Deep Learning, Machine L...	No especificado	No especificado
[180]	Improvement of Lightweight Convolutional Neural Network Model Based on YOLO Algorithm a...	YOLOv5, YOLOv3, YOLO, CNN (Redes...	No especificado	No especificado
[181]	Research on Pedestrian Detection and DeepSort Tracking in Front of Intelligent Vehicle ...	YOLO, Deep Learning	No especificado	No especificado
[182]	Object Detection of Pedestrian Crossing Accident Using Deep Convolutional Neural Networks	YOLOv3, Faster R-CNN, CNN (Redes...	Videovigilancia / CCTV	No especificado
[183]	Automatic detection system of speed violations in a traffic based on deep learning tech...	YOLO, Deep Learning	No especificado	No especificado
[184]	Detection of Unauthorized Unmanned Aerial Vehicles Using YOLOv5 and Transfer Learning	YOLOv5	UAV / Drones	No especificado
[185]	Automatic Traffic Red-Light Violation Detection Using AI	YOLOv5, Machine Learning	No especificado	86 % accuracy, accuracy of 82
[186]	Detection of Two-Wheeler Traffic Rule Violation Using Deep Learning	YOLOv5, RetinaNet, Deep Learning	No especificado	92.6 % accuracy, accuracy of 92.6
[187]	Anomaly Detection in Traffic Surveillance Videos Using Deep Learning	CNN (Redes Convolucionales), Dee...	Videovigilancia / CCTV	accuracy of 82
[188]	Real-Time Accident Detection in Traffic Surveillance Using Deep Learning	YOLOv4, Deep Learning	Videovigilancia / CCTV	No especificado
[189]	Traffic sign recognition based on deep learning	YOLOv5, SSD, CNN (Redes Convolut...	No especificado	90.14 % mAP, 97.70 % mAP
[190]	Method For Detecting Violation at a Pedestrian Crossing Using a Convolutional Neural N...	YOLO, CNN (Redes Convolucionales)	No especificado	No especificado

Tabla XIII
RESUMEN DE INVESTIGACIONES EN DETECCIÓN DE INFRACCIONES Y ACCIDENTES DE TRÁNSITO (PARTE 5)

Ref.	Título del Trabajo	Metodología IA	Entorno de Prueba	Métrica de Rendimiento
[191]	Unmanned Aerial Multi-Object Dynamic Frame Detection and Skipping Using Deep Learning o...	Deep Learning	UAV / Drones	No especificado
[192]	Real-time image enhancement for an automatic automobile accident detection through CCTV...	YOLO, SVM, Deep Learning, Machin...	Videovigilancia / CCTV	28 frames per second, 12.73 ms
[193]	Effective Anomaly Detection Using Deep Learning in IoT Systems	Autoencoder, Deep Learning	No especificado	No especificado
[194]	Deep learning based detection and localization of road accidents from traffic surveilla...	Deep Learning	No especificado	No especificado
[195]	Deep Neural Networks Based Object Detection for Road Safety Using YOLO-V3	YOLO, CNN (Redes Convolucionales...	Videovigilancia / CCTV	accuracy of 86.3
[196]	Object Detection Using Deep Learning Methods in Traffic Scenarios	Deep Learning	No especificado	No especificado
[197]	Network Abnormal Traffic Detection Model Based on Semi-Supervised Deep Reinforcement Le...	Autoencoder, Machine Learning, R...	No especificado	No especificado
[198]	Monitoring and surveillance of urban road traffic using low altitude drone images: a de...	YOLOv4, YOLOv3, SSD, Deep Learning	UAV / Drones	No especificado
[199]	A Vision-based System for Traffic Anomaly Detection using Deep Learning and Decision Trees	YOLOv5, Deep Learning	Videovigilancia / CCTV	F1 score of 0.8571
[200]	Automatic Detection of Traffic Accidents from Video Using Deep Learning Techniques	Deep Learning	No especificado	98 % accuracy, accuracy of 98
[201]	Scene-Graph Augmented Data-Driven Risk Assessment of Autonomous Vehicle Decisions	No especificado	No especificado	70.3 % accuracy, accuracy of 87.8
[202]	Detection and response to critical lead vehicle deceleration events with peripheral vis...	No especificado	No especificado	No especificado
[203]	Traffic Signal Violation Detection using Artificial Intelligence and Deep Learning	YOLOv3, Deep Learning	No especificado	accuracy of 97.67, accuracy of 8...
[204]	Anomaly Detection in Road Traffic Using Visual Surveillance	Deep Learning	Conducción naturalista / Vehicul...	No especificado
[205]	Traffic Rules Violation Detection using Deep Learning	YOLO, Mask R-CNN, CNN (Redes Con...	No especificado	No especificado
[206]	An Unsupervised Deep Learning Model for Early Network Traffic Anomaly Detection	CNN (Redes Convolucionales), Aut...	No especificado	100 % accuracy
[207]	Anomaly detection framework for Internet of things traffic using vector convolutional d...	Deep Learning	No especificado	No especificado
[208]	Object Detection and Tracking with UAV Data Using Deep Learning	LSTM, Deep Learning	UAV / Drones	No especificado
[209]	Adoption and realization of deep learning in network traffic anomaly detection device d...	CNN (Redes Convolucionales), Dee...	No especificado	No especificado
[210]	Real World Object Detection Dataset for Quadcopter Unmanned Aerial Vehicle Detection	Machine Learning	UAV / Drones	No especificado
[211]	Deep neural network based anomaly detection in Internet of Things network traffic track...	Deep Learning, Machine Learning	No especificado	No especificado
[212]	Deep learning and handcrafted features for one-class anomaly detection in UAV video	CNN (Redes Convolucionales), SVM...	UAV / Drones	No especificado
[213]	Dynamic All-Red Signal Control Based on Deep Neural Network Considering Red Light Runne...	CNN (Redes Convolucionales)	No especificado	No especificado

drásticamente incrementada gracias al uso de modelos basados en marcas faciales y redes convolucionales espaciotemporales. Trabajos como los recopilados en [15, 18] demuestran que el análisis ocular y bucal combinado previene efectivamente colisiones reales viales en vehículos comerciales. Por otro lado, la clasificación de emociones del conductor en tiempo real mediante deep learning [26, 21] permite estimar estados de ira, estrés o cansancio crónico que correlacionan directamente con una conducción agresiva o errática.

En lo que respecta a la detección de infracciones y monitoreo de tráfico, los estudios destacan la transición de detectores estáticos a sistemas dinámicos inteligentes de control. El uso de la familia YOLO en intersecciones urbanas complejas ha permitido rastrear y clasificar vehículos simultáneamente, identificando infracciones críticas como el giro indebido, el cruce de semáforo en rojo o el exceso de velocidad instantáneo mediante el cálculo de distancias relativas entre cuadros. Estudios en CCTV [9, 21] y bajo tomas aéreas [116, 120] recalcan que las arquitecturas modernas superan la latencia de procesamiento requerida, logrando tasas de precisión robustas en entornos metropolitanos de alta congestión.

IV-B. Inteligencia Artificial Explicable (XAI) en Seguridad Activa

La falta de interpretabilidad en las decisiones de los modelos de Deep Learning (el problema de la caja negra”) representa una barrera significativa para la certificación industrial de sistemas de asistencia al conductor (ADAS) [21, 22]. Ante una alerta de fatiga o distracción, es indispensable auditar si el modelo basó su predicción en patrones válidos (como la tasa de cierre de párpados o el bostezo) o en sesgos irrelevantes del fondo o del sujeto [23, 116]. Estudios recientes proponen el uso de técnicas de XAI visual, como Grad-CAM (Gradient-weighted Class Activation Mapping) [117, 118], para generar mapas de calor sobre el rostro que resaltan las regiones críticas de decisión en tiempo de inferencia, garantizando la auditabilidad y fomentando la confianza del usuario final.

IV-C. El Desafío 'In-the-Wild' y la Transferibilidad de Dominios

Una limitación crítica en el estado del arte es el sesgo de los datasets de entrenamiento, los cuales suelen ser capturados en laboratorios con condiciones controladas de luz y pose. Al desplegar estos modelos en la conducción naturalista real (in-the-wild”), se observa un decremento sustancial en el desempeño debido a la vibración del vehículo, reflejos del parabrisas y variabilidad climática extrema [52, 58]. Para superar esta limitación, las investigaciones se orientan al desarrollo de técnicas de Adaptación de Dominio No Supervisada (UDA) [119, 42] y al entrenamiento auto-supervisado, permitiendo que el sistema adapte su representación de características de un entorno sintético o controlado hacia la dinámica del mundo real sin requerir un costoso etiquetado manual adicional [120, 121].

V. LIMITACIONES TÉCNICAS Y DESAFÍOS

A pesar de los avances sobresalientes documentados en la literatura científica reciente, los autores de la literatura revisada identifican varios inconvenientes técnicos y operativos recurrentes que restringen la generalización de estas tecnologías en la práctica [30, 24, 25].

V-A. Variabilidad Lumínica y Oclusión

Los cambios repentinos en las condiciones de iluminación, tales como la transición rápida al entrar o salir de túneles viales, el deslumbramiento solar directo, las sombras complejas proyectadas por árboles u otras estructuras urbanas, y la conducción puramente nocturna, degradan de forma severa el contraste de las imágenes capturadas [38, 122]. Esto incrementa sustancialmente los falsos negativos en modelos de detección facial o de seguimiento vehicular [43, 123].

Adicionalmente, la oclusión parcial o total de objetos (por ejemplo, camiones de gran tonelaje bloqueando la línea de visión de cámaras fijas respecto a peatones o vehículos pequeños en cruces) continúa siendo un problema técnico complejo [118, 38]. En el monitoreo de conductores, las oclusiones debidas al uso de anteojos de sol, tapabocas o movimientos naturales de las manos sobre el volante representan fuentes críticas de error que interrumpen el rastreo de marcas faciales esenciales [22, 117].

V-B. Restricciones de Hardware y Requerimientos de Tiempo Real

El procesamiento a alta velocidad (típicamente a más de 30 FPS) es una condición indispensable para garantizar la seguridad activa y alertar a tiempo al conductor o al centro de monitoreo de tráfico. Sin embargo, los modelos de Deep Learning más precisos conllevan una alta complejidad paramétrica y un elevado consumo energético, lo que limita su despliegue en hardware de bajo costo y potencia reducida (Edge Computing) [65, 68]. Esto fuerza la necesidad de aplicar técnicas avanzadas de optimización, tales como la cuantización de modelos a precisión de 8 bits, la destilación de conocimiento (knowledge distillation) de redes grandes a redes pequeñas y la poda de canales (channel pruning) [124, 125], asumiendo en ocasiones una pérdida marginal en la exactitud a cambio de viabilidad operativa.

Aunado a la latencia intrínseca de los modelos, la sincronización temporal y espacial de múltiples flujos de video en tiempo real representa otro desafío operativo de gran envergadura en despliegues prácticos [39, 126]. En entornos urbanos donde se recopila información de múltiples cámaras de CCTV en intersecciones contiguas, o en sistemas a bordo que integran sensores ópticos periféricos para cubrir los puntos ciegos del vehículo, la falta de alineación de tiempo en milisegundos (jitter de red) puede provocar falsas detecciones de velocidad o errores en el seguimiento continuo (multi-camera tracking) de un mismo vehículo a través de la red vial. Esta desalineación temporal deteriora la precisión de la reconstrucción tridimensional de la escena y limita la confiabilidad del sistema ante eventos dinámicos rápidos.

V-C. Sesgo en los Datos y Generalización

Una limitación crítica compartida por gran parte de los estudios analizados es el desequilibrio en los conjuntos de datos de entrenamiento [24, 52]. La mayoría de los datasets públicos de fatiga y distracción se graban bajo entornos de laboratorio controlados con un número limitado de sujetos y condiciones de luz uniformes [16, 34]. Al transferir estos modelos preentrenados a escenarios del mundo real, se observa una degradación drástica del rendimiento, lo que resalta la falta de capacidad de generalización entre dominios cruzados (cross-domain generalization) [72, 73]. Asimismo, existe un sesgo demográfico marcado en los conjuntos de datos de rostros, lo que afecta la exactitud de los algoritmos de detección en personas con distintos rasgos étnicos o estructuras faciales no representadas en los datos de entrenamiento iniciales.

La Fig. 8 muestra la distribución cruzada de la incidencia de estas limitaciones según el enfoque metodológico de los artículos científicos analizados.




Figura 8. Incidencia de Limitaciones según el Enfoque Metodológico de la Investigación.

Para complementar esta perspectiva, la Fig. 9 correlaciona la presencia de estos desafíos técnicos frente a los entornos de validación experimental. Se evidencia que los problemas de iluminación y la oclusión visual predominan en cámaras de circuito cerrado (CCTV) debido a factores climáticos descontrolados [123, 31], mientras que la latencia y restricciones de hardware crítico representan los mayores obstáculos en el despliegue embebido a bordo y en vehículos aéreos (UAV) [137, 143].

V-D. Desafíos de Privacidad, Ética y Seguridad de Datos

El despliegue masivo de sistemas de monitoreo de conductores y cámaras de videovigilancia urbana plantea serios desafíos éticos y de privacidad de datos que deben ser abordados rigurosamente por los diseñadores de políticas públicas y desarrolladores de tecnología [127, 128]. La captura continua del rostro del conductor, el análisis de sus expresiones emocionales y el seguimiento de su mirada recopilan información biométrica de carácter altamente sensible. Si estos datos son transmitidos sin encriptación o almacenados de manera centralizada en




Figura 9. Correlación de Limitaciones e Inconvenientes vs. Entorno Experimental.

servidores de la nube, se crea un riesgo latente de vulneración de la privacidad y acceso no autorizado por terceros [129, 33].

Normativas internacionales estrictas, como el Reglamento General de Protección de Datos (GDPR) en Europa, exigen que el procesamiento de datos biométricos se realice bajo principios de minimización de datos y consentimiento explícito. En respuesta a estos desafíos, la tendencia actual en el estado del arte se orienta fuertemente hacia el procesamiento en el borde (Edge Computing), donde la inferencia del modelo se ejecuta directamente dentro del hardware instalado en el vehículo (por ejemplo, microcontroladores avanzados o procesadores embebidos NVIDIA Jetson) [44, 45]. Al procesar las imágenes localmente y descartar de inmediato los fotogramas del video, transmitiendo únicamente alertas de metadatos (como "somnolencia detectada"), se resguarda de forma efectiva la identidad y privacidad del conductor, garantizando al mismo tiempo una baja latencia en la emisión de advertencias de seguridad.

Para mitigar los riesgos asociados con la transmisión de videos biométricos sensibles a servidores en la nube, el Aprendizaje Federado (Federated Learning) se posiciona como una solución altamente prometedora en la literatura reciente [27, 130]. Bajo este paradigma, los dispositivos embebidos en el borde a bordo de múltiples vehículos entrenan de forma colaborativa un modelo global compartiendo únicamente las actualizaciones de gradientes cifrados, sin exponer jamás la información biométrica cruda o el video del rostro a servidores centrales. Esto no solo garantiza el cumplimiento de normativas de privacidad rigurosas como la GDPR [31, 131], sino que también reduce sustancialmente el ancho de banda necesario en redes móviles vehiculares (V2X).

VI. CONCLUSIONES Y TRABAJO FUTURO

La presente revisión sistemática del estado del arte ha permitido evaluar de manera integral el desarrollo, madurez y desafíos actuales de las soluciones de visión computacional y aprendizaje automático aplicadas a los sistemas de transporte inteligentes y el monitoreo de conductores. A través del análisis estadístico cuantitativo del corpus de 213 publicaciones,

se evidencia una consolidación científica significativa que está transformando el control y seguridad de nuestras redes viales.

Las conclusiones principales obtenidas de este análisis global son:

- La hegemonía metodológica ha migrado casi en su totalidad hacia soluciones de Deep Learning debido a su alta capacidad de generalización en entornos urbanos dinámicos.
- El hardware embebido (Edge Computing) es fundamental para lograr implementaciones en tiempo real que garanticen la privacidad del conductor y baja latencia de procesamiento.
- Los desafíos actuales se centran en mitigar la sensibilidad de los modelos ante cambios climáticos y problemas de iluminación.

Como trabajo futuro, se vislumbran tres grandes áreas de desarrollo prioritarias en la literatura científica reciente:

1. **Fusión de Sensores Multimodales:** La combinación de datos visuales con señales biométricas (EEG, ECG, conductancia de la piel) o datos espaciales (LiDAR, Radar) para robustecer la detección frente a oclusiones y cambios de iluminación.
2. **Modelos de Lenguaje-Visión (Vision-Language Models) y Aprendizaje Zero-Shot:** La incorporación de arquitecturas multimodales que permitan detectar conductas atípicas de riesgo sin depender exclusivamente de clases predefinidas de entrenamiento.
3. **Generación de Datos Sintéticos:** El uso de Redes Generativas Adversarias (GAN) y modelos de difusión para generar imágenes realistas de conducción nocturna, oclusiones y accidentes, resolviendo el problema de escasez de datos balanceados de entrenamiento.

REFERENCIAS

- [1] Ajay Kumar et al. (2026a). "Intelligent Traffic Accident Detection System using Deep Learning Fusion Techniques". En: *2026 International Conference on AI-Driven Smart Systems and Ubiquitous Computing (ICAUC)*. DOI: 10.1109/icauc68182.2026.11441302.
- [2] Syed Jamaluddin Ahmad et al. (2026). "A Comparative Evaluation of Deep Learning Models for Road Accident Detection Using CCTV Images and Dashcam Videos". En: *Journal of Sensors*. DOI: 10.1155/js/2985368.
- [3] Gyanendra Kumar et al. (2026b). "UAV-based object detection model for smart surveillance using deep neural network". En: *Measurement: Sensors*. DOI: 10.1016/j.measen.2025.101982.
- [4] Qingning Chen et al. (2026). "Hybrid Deep Learning and Classification Framework for Automatic Traffic Inspection Classification Based on Image Detection". En: *Transactions on Emerging Telecommunications Technologies*. DOI: 10.1002/ett.70325.
- [5] Yunpeng Liu y Joan Lazaro (2026). "Research on the Analysis and Recognition System for Dangerous Driving Behaviors Based on Convolutional Neural Networks". En: *Journal of Computer, Signal, and System Research*. DOI: 10.71222/7k53hy91.
- [6] Arash Abarghoeei y Mojtaba Ahmadi (2026). "Driving Behavior Classification and Risk Quantification via Multisensor Machine Learning: From Simulation to Reality". En: *IEEE Transactions on Instrumentation and Measurement*. DOI: 10.1109/tim.2026.3654736.
- [7] Chuanfei Hu, Xinde Li y Jianxin Pang (2026). "Trustworthy Driver State Perception via Contextual Interaction-Driven Evidential Vision-Language Fusion in Vehicular Cyber-Physical Systems". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2025.3542447.
- [8] D. Srivastava y Ratnesh Litoriya (2026). "Traffic Violations Control Using Deep Learning". En: *2026 4th International Conference on Intelligent Data Communication Technologies and Internet of Things (ID-CIoT)*. DOI: 10.1109/idciot67589.2026.11455678.
- [9] K.S.V. Sai Sri Phanindra Pavan et al. (2026). "AI-Powered Traffic Violation Detection System Using CCTV, and Deep Learning". En: *INTERNATIONAL JOURNAL OF SCIENTIFIC RESEARCH IN ENGINEERING AND MANAGEMENT*. DOI: 10.55041/ijssrem58855.
- [10] Huma Zia et al. (2025). "Advancing Road Safety: A Comprehensive Evaluation of Object Detection Models for Commercial Driver Monitoring Systems". En: *Future Transportation*. DOI: 10.3390/futuretransp5010002.
- [11] Yagnik M. Bhavsar et al. (2025). "Evaluating Defensive Driving Behaviour Based on Safe Distance Between Vehicles: A Case Study Using Computer Vision on UAV Videos at Urban Roundabout". En: *Multimodal Transportation*. DOI: 10.1016/j.multra.2025.100227.
- [12] Tamia Zambrano et al. (2026). "Driver Monitoring System Using Computer Vision for Real-Time Detection of Fatigue, Distraction and Emotion via Facial Landmarks and Deep Learning". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s26030889.
- [13] F. Rahman et al. (2026). "A Cost-Effective Intelligent Edge-Based Driver Monitoring System for Real-Time Detection of Unsafe Driving Behaviors". En: *2026 International Conference on Computing, Networking and Communications (ICNC)*. DOI: 10.1109/icnc68183.2026.11416852.
- [14] Chayadevi M L, S. Uday y Sourav Mantesh Shet (2026). "SafeStreets: Deep Learning-Based Real-Time Traffic Violation Detection System". En: *2026 International Conference on Intelligent and Innovative Technologies in Computing, Electrical and Electronics (IITCEE)*. DOI: 10.1109/iitcee67948.2026.11394149.

- [15] Dongmin Kim, Hwanpil Lee y Jooyoung Lee (2025). "Unsupervised Learning Approach for Risky Driving Behavior Identification on Expressways in C-ITS Environments". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2025.3538929.
- [16] Siman Wu et al. (2025). "Visual Risk-Aware Decision-Making Method for Autonomous Driving". En: *2025 IEEE International Conference on Unmanned Systems (ICUS)*. DOI: 10.1109/icus66297.2025.11294445.
- [17] Lei Yang et al. (2025). "Computer Vision-Based Traffic Monitoring: Design of a Red-Light Violation Detection System for Urban Intersections". En: *2025 5th International Symposium on Computer Technology and Information Science (ISCTIS)*. DOI: 10.1109/isctis65944.2025.11065596.
- [18] Siham Essahraoui et al. (2025). "Real-Time Driver Drowsiness Detection Using Facial Analysis and Machine Learning Techniques". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s25030812.
- [19] Z. Jing (2025). "Traffic Incident Detection Algorithm based on Deep Learning: A Statistical Optimization Approach". En: *2025 International Conference on Electronics and Renewable Systems (ICEARS)*. DOI: 10.1109/icears64219.2025.10940611.
- [20] Muhammad Rajendra Aria Satya et al. (2025). "Utilization of YoloV8 Algorithm for in-Vehicle Video-Based Driver Monitoring System". En: *Journal of Artificial Intelligence and Engineering Applications (JAIEA)*. DOI: 10.59934/jaiea.v4i3.998.
- [21] Thien-Doanh Le et al. (2025). "Red-light Running Detection". En: *J. Univers. Comput. Sci.* DOI: 10.3897/jucs.150763.
- [22] Tiago Silva, T. M. Dias y P. Jorge (2025). "Red Light Running Detection Using AI-Powered Object Tracking on Embedded Systems". En: *2025 9th International Young Engineers Forum on Electrical and Computer Engineering (YEF-ECE)*. DOI: 10.1109/yef-ece66503.2025.11117531.
- [23] Mustapha Oussouaddi et al. (2025). "DSR-YOLO: A Lightweight and Efficient YOLOv8 Model for Enhanced Pedestrian Detection". En: *Cognitive Robotics*. DOI: 10.1016/j.cogr.2025.04.001.
- [24] Mohammed Alshehri et al. (2025). "Integrated neural network framework for multi-object detection and recognition using UAV imagery". En: *Frontiers in Neurorobotics*. DOI: 10.3389/fnbot.2025.1643011.
- [25] Yuchen Xie, Danfeng Du y Mengju Bi (2025). "YOLO-ACE: A Vehicle and Pedestrian Detection Algorithm for Autonomous Driving Scenarios Based on Knowledge Distillation of YOLOv10". En: *IEEE Internet of Things Journal*. DOI: 10.1109/jiot.2025.3569735.
- [26] Hui Lin (2025). "Dangerous Driving Behavior Detection Based on Computer Vision". En: *2025 IEEE 3rd International Conference on Electrical, Automation and Computer Engineering (ICEACE)*. DOI: 10.1109/iceace67491.2025.11439288.
- [27] Jyotirmaya Ijaradar et al. (2025). "Data-Driven Anomaly Detection in Urban Traffic Data: A Deep Learning Approach". En: *2025 9th International Conference on Models and Technologies for Intelligent Transportation Systems (MT-ITS)*. DOI: 10.1109/mt-its68460.2025.11223545.
- [28] Mengmeng Duan, Shaowei Sun y Mingzhou Liu (2025). "A multimodal deep fusion framework for highway traffic anomaly detection". En: *Scientific Reports*. DOI: 10.1038/s41598-025-18671-x.
- [29] Tamilselvan Arjunan (2024). "Real-Time Detection of Network Traffic Anomalies in Big Data Environments Using Deep Learning Models". En: *International Journal for Research in Applied Science and Engineering Technology*. DOI: 10.22214/ijraset.2024.58946.
- [30] Yinji Huang y Fuyuan Wang (2025). "D-TLDDetector: Advancing Traffic Light Detection With a Lightweight Deep Learning Model". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2024.3522195.
- [31] Kalluri Ravi Kumar y MRS. SUREKHA (2025). "The Smart City Transportation: Deep Learning Ensemble Approach for Traffic Accident Detection". En: *Journal of Engineering Sciences*. DOI: 10.36893/jes.2025.v16i04.030.
- [32] T. Tran et al. (2024). "Transformer-Based Spatio-Temporal Unsupervised Traffic Anomaly Detection in Aerial Videos". En: *IEEE Transactions on Circuits and Systems for Video Technology*. DOI: 10.1109/tcsvt.2024.3376399.
- [33] Md. Ashraf Uddin et al. (2025). "Abnormal Driving Behavior Detection: A Machine and Deep Learning Based Hybrid Model". En: *International Journal of Intelligent Transportation Systems Research*. DOI: 10.1007/s13177-025-00471-2.
- [34] Sheikh M. Usman et al. (2024). "Detection of distracted driving through the analysis of real-time driver, vehicle, and roadway volatilities". En: *Journal of Transportation Safety & Security*. DOI: 10.1080/19439962.2024.2341393.
- [35] Xiaolin Wu, Changcheng Shi y Lirong Yan (2024). "Driving Attention State Detection Based on GRU-EEGNet". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s24165086.
- [36] Qingwan Xue et al. (2023). "Young Novice Drivers' Cognitive Distraction Detection: Comparing Support Vector Machines and Random Forest Model of Vehicle Control Behavior". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23031345.
- [37] Bing-Ting Dong, Huei-Yung Lin y Chin-Chen Chang (2022). "Driver Fatigue and Distracted Driving Detection Using Random Forest and Convolutional Neu-

- ral Network". En: *Applied Sciences*. DOI: 10.3390/app12178674.
- [38] R. Mota et al. (2025). "Integration of deep learning algorithms for real-time vehicle accident detection from surveillance videos". En: *Bulletin of Electrical Engineering and Informatics*. DOI: 10.11591/eei.v14i5.9587.
- [39] Mr. S. Suresh et al. (2025). "Traffic Violation Detection Using Deep Learning". En: *International Research Journal on Advanced Engineering and Management (IRJAEM)*. DOI: 10.47392/irjaem.2025.0221.
- [40] Majun Fei et al. (2025). "Enhancing Driving Safety Evaluation Through Correlation Analysis of Driver Behavior". En: *Sustainability*. DOI: 10.3390/su17094067.
- [41] Dachuan Zuo et al. (2025). "Composite Safety Potential Field for Highway Driving Risk Assessment". En: *Accident; analysis and prevention*. DOI: 10.48550/arxiv.2504.21158.
- [42] Anupam Yadav et al. (2025). "Enhancing convolutional neural networks in electroencephalogram driver drowsiness detection using human inspired optimizers". En: *Scientific Reports*. DOI: 10.1038/s41598-025-93765-0.
- [43] Rakesh Salakapuri et al. (2025). "Integrated deep learning framework for driver distraction detection and real-time road object recognition in advanced driver assistance systems". En: *Scientific Reports*. DOI: 10.1038/s41598-025-08475-4.
- [44] Ian Nell y Shane Gilroy (2025). "Classification of Driver Behaviour Using External Observation Techniques for Autonomous Vehicles". En: *2025 13th International Conference on Control, Mechatronics and Automation (ICCA)*. DOI: 10.1109/icca67641.2025.11369693.
- [45] Neero Gumsar Sorum y Martina Gumsar Sorum (2025). "Modeling of injury severity of distracted driving accident using statistical and machine learning models". En: *PLOS One*. DOI: 10.1371/journal.pone.0326113.
- [46] Zhaowen Pang et al. (2025). "Risk Assessment Method for Autonomous Vehicles Violating Safety Common Sense Based on Driving Behavior". En: *IEEE Access*. DOI: 10.1109/access.2025.3552833.
- [47] Arafat Sahin Afridi et al. (2025). "A multi-class driver behavior dataset for real-time detection and road safety enhancement". En: *Data in Brief*. DOI: 10.1016/j.dib.2025.111529.
- [48] B. B. Gupta et al. (2024). "Deep Learning Model for Driver Behavior Detection in Cyber-Physical System-Based Intelligent Transport Systems". En: *IEEE Access*. DOI: 10.1109/access.2024.3393909.
- [49] Adil Salbi et al. (2024). "Design and implementation of a driving safety assistant system based on driver behavior". En: *IAES International Journal of Artificial Intelligence (IJ-AI)*. DOI: 10.11591/ijai.v13.i3.pp2603-2613.
- [50] Kunpeng Zhang et al. (2024). "Integrating visual large language model and reasoning chain for driver behavior analysis and risk assessment." En: *Accident; analysis and prevention*. DOI: 10.1016/j.aap.2024.107497.
- [51] Pavana Pradeep Kumar, Krishna Kant y Amitangshu Pal (2024). "Nonintrusive Driving Behavior Characterization From Road-Side Cameras". En: *IEEE Internet of Things Journal*. DOI: 10.1109/jiot.2023.3285886.
- [52] Duo Lu et al. (2024). "Validation and Analysis of Driving Safety Assessment Metrics in Real-world Car-Following Scenarios with Aerial Videos". En: *SAE Technical Paper Series*. DOI: 10.4271/2024-01-2020.
- [53] Ayoub Charef, Zahi Jarir y Mohamed Quafafou (2024). "Assessing the driving behaviour of motorcyclists to improve road safety". En: *J. Univers. Comput. Sci.* DOI: 10.3897/jucs.108550.
- [54] Argha Sen et al. (2024). "Passive Monitoring of Dangerous Driving Behaviors Using mmWave Radar". En: *Pervasive Mob. Comput.* DOI: 10.1016/j.pmcj.2024.101949.
- [55] Anchang Liu y Jing Bai (2024). "Safety Driving Detection Based on Convolution Neural Network". En: *2024 5th International Conference on Computer Vision, Image and Deep Learning (CVIDL)*. DOI: 10.1109/cvidl62147.2024.10604042.
- [56] Geqi Qi et al. (2024). "Augmented Recognition of Distracted Driving State Based on Electrophysiological Analysis of Brain Network". En: *Cyborg and Bionic Systems*. DOI: 10.34133/cbsystems.0130.
- [57] Reem Jalal Eddine, Claudio Mulatti y Francesco N. Biondi (2024). "On investigating drivers' attention allocation during partially-automated driving". En: *Cognitive Research: Principles and Implications*. DOI: 10.1186/s41235-024-00549-7.
- [58] Zulqarnain H. Khattak et al. (2024). "The role of driver head pose dynamics and instantaneous driving in safety critical events: Application of computer vision in naturalistic driving." En: *Accident; analysis and prevention*. DOI: 10.1016/j.aap.2024.107545.
- [59] R. Chadha, Jugesh y Jasmehar Singh (2024). "Enhancing Road Safety: A Driver Fatigue Detection and Behaviour Monitoring System using Advanced Computer Vision Techniques". En: *June 2024*. DOI: 10.36548/jucct.2024.2.004.
- [60] Hongxiang Lin et al. (2024). "Realization of a Safe Driving Monitoring System for Motor Vehicles". En: *2024 8th International Conference on Automation, Control and Robots (ICACR)*. DOI: 10.1109/icacr62205.2024.11053711.
- [61] Ruijie Li et al. (2024a). "YOLO-SGC: A Dangerous Driving Behavior Detection Method With Multiscale

- Spatial-Channel Feature Aggregation”. En: *IEEE Sensors Journal*. DOI: 10.1109/jsen.2024.3457686.
- [62] Fangming Qu et al. (2024). “Comprehensive study of driver behavior monitoring systems using computer vision and machine learning techniques”. En: *Journal of Big Data*. DOI: 10.1186/s40537-024-00890-0.
- [63] Joao Felipe Gobeti Calenzani et al. (2024). “A Study on the Effectiveness of GPT-4V in Classifying Driver Behavior Captured on Video Using Just a Few Frames per Video”. En: *2024 International Joint Conference on Neural Networks (IJCNN)*. DOI: 10.1109/ijcnn60899.2024.10650751.
- [64] Marina Pi-Ruano, Javier Roca y P. Tejero (2024). “Audiovisual presentation of variable message signs improves message processing in distracted drivers during partially automated driving.” En: *Journal of safety research*. DOI: 10.1016/j.jsr.2024.01.014.
- [65] Md. Mostafizur Rahman Komol et al. (2024). “Prediction of Drivers’ Red-Light Running Behaviour in Connected Vehicle Environments Using Deep Recurrent Neural Networks”. En: *Mach. Learn. Knowl. Extr.* DOI: 10.3390/make6040136.
- [66] Maleika Heenaye-Mamode Khan et al. (2024). “An Enhanced Deep Neural Network Model for the Detection of Anomalous Behavior of Drivers in Road Traffic”. En: *Journal of Sensors*. DOI: 10.1155/js/5295932.
- [67] Yashar Jebraeily, Y. Sharafi y Mohammad Teshnehlab (2024). “Driver Drowsiness Detection Based on Convolutional Neural Network Architecture Optimization Using Genetic Algorithm”. En: *IEEE Access*. DOI: 10.1109/access.2024.3381999.
- [68] Jaira -Salayon- Hernandez et al. (2024). “Real-time driver drowsiness and distraction detection using convolutional neural network with multiple behavioral features”. En: *World Journal of Advanced Research and Reviews*. DOI: 10.30574/wjarr.2024.23.1.1976.
- [69] Tee Connie, Ryan Wee y Michael Kah Ong Goh (2024). “Wrong-Way Driving Detection for Enhanced Road Safety using Computer Vision and Machine Learning Techniques”. En: *International Journal on Advanced Science, Engineering and Information Technology*. DOI: 10.18517/ijaseit.14.6.12376.
- [70] B. Vamshi et al. (2023). “Detection of Distracted Driver Using Convolutional Neural Network”. En: *International Journal for Research in Applied Science and Engineering Technology*. DOI: 10.22214/ijraset.2023.54176.
- [71] Anna Charly y Tom V. Mathew (2023). “Identifying risky driving behavior: a field study using instrumented vehicles”. En: *Transportation Letters*. DOI: 10.1080/19427867.2023.2233782.
- [72] Megan D Mulhall et al. (2023). “European NCAP Driver State Monitoring Protocols: Prevalence of Distraction in Naturalistic Driving”. En: *Human Factors*. DOI: 10.1177/00187208231194543.
- [73] A. J. Galloway et al. (2023). “Evaluation of intersection crashes using naturalistic driving data through the lens of future I-ADAS”. En: *Traffic Injury Prevention*. DOI: 10.1080/15389588.2023.2237621.
- [74] Roja Ezzati Amini et al. (2023). “Driver distraction and in-vehicle interventions: A driving simulator study on visual attention and driving performance.” En: *Accident; analysis and prevention*. DOI: 10.1016/j.aap.2023.107195.
- [75] Duo Zhang et al. (2023). “Real-time driving risk assessment based on the psycho-physical field”. En: *Journal of Transportation Safety & Security*. DOI: 10.1080/19439962.2023.2208065.
- [76] M. Gu, Kaiyu Chen y Zhixiang Chen (2023). “RFDA-Net: an FMCW and TOF radar fusion approach for driver activity recognition using multi-level attention based CNN and LSTM network”. En: *Complex & Intelligent Systems*. DOI: 10.1007/s40747-023-01236-8.
- [77] Mohammed Imran Basheer Ahmed et al. (2023a). “A Deep-Learning Approach to Driver Drowsiness Detection”. En: *Safety*. DOI: 10.3390/safety9030065.
- [78] Fiaz Majeed et al. (2023). “Detection of Drowsiness among Drivers Using Novel Deep Convolutional Neural Network Model”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23218741.
- [79] Jiajing Chen et al. (2023). “Vision-Language Models Can Identify Distracted Driver Behavior From Naturalistic Videos”. En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2024.3381175.
- [80] Narsaiah Domala et al. (2023). “Detection of Unsafe Driving and Drivers Behaviour Monitoring System”. En: *Proceeding International Conference on Science and Engineering*. DOI: 10.52783/cienceng.v11i1.374.
- [81] Furkat Safarov et al. (2023). “Real-Time Deep Learning-Based Drowsiness Detection: Leveraging Computer-Vision and Eye-Blink Analyses for Enhanced Road Safety”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23146459.
- [82] Alexandra Fries et al. (2023). “Modeling driver behavior in critical traffic scenarios for the safety assessment of automated driving”. En: *Traffic Injury Prevention*. DOI: 10.1080/15389588.2023.2211187.
- [83] Pooyan Khosravinia, T. Perumal y Javad Zarrin (2023). “Enhancing Road Safety Through Accurate Detection of Hazardous Driving Behaviors With Graph Convolutional Recurrent Networks”. En: *IEEE Access*. DOI: 10.1109/access.2023.3280473.
- [84] Haixiao Wang, Xu Ding y Chutong Wang (2023). “Risk Assessment of Distracted Driving Behavior Based on Visual Stability Coefficient”. En: *Journal*

- of *Advanced Transportation*. DOI: 10.1155/2023/2111532.
- [85] A. Savkin et al. (2022). "Unusual Driver Behavior Detection in Videos Using Deep Learning Models". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23010311.
- [86] Denggui Wang et al. (2022). "Potential risk assessment for safe driving of autonomous vehicles under occluded vision". En: *Scientific Reports*. DOI: 10.1038/s41598-022-08810-z.
- [87] Dulanjana M. Perera et al. (2022). "Improving EEG-Based Driver Distraction Classification Using Brain Connectivity Estimators". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s22166230.
- [88] Longxi Luo et al. (2022). "Detecting Driver Cognition Alertness State From Visual Activities in Normal and Emergency Scenarios". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2022.3166251.
- [89] Pintusorn Suttiponpisarn et al. (2022). "An Autonomous Framework for Real-Time Wrong-Way Driving Vehicle Detection from Closed-Circuit Televisions". En: *Sustainability*. DOI: 10.3390/su141610232.
- [90] Prachi Panwar et al. (2022). "DDNet- A Deep Learning Approach to Detect Driver Distraction and Drowsiness". En: *Evergreen*. DOI: 10.5109/4843120.
- [91] Weichu Xiao et al. (2022). "Attention-based deep neural network for driver behavior recognition". En: *Future Gener. Comput. Syst.* DOI: 10.1016/j.future.2022.02.007.
- [92] A. Haghighat y Anand Sharma (2022). "A computer vision-based deep learning model to detect wrong-way driving using pan-tilt-zoom traffic cameras". En: *Computer-Aided Civil and Infrastructure Engineering*. DOI: 10.1111/mice.12819.
- [93] Abid Ali Minhas et al. (2022). "A smart analysis of driver fatigue and drowsiness detection using convolutional neural networks". En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-022-13193-4.
- [94] Deyun Wang (2022). "Intelligent Detection of Vehicle Driving Safety Based on Deep Learning". En: *Wireless Communications and Mobile Computing*. DOI: 10.1155/2022/1095524.
- [95] M. Hossain et al. (2022). "Automatic driver distraction detection using deep convolutional neural networks". En: *Intell. Syst. Appl.* DOI: 10.1016/j.iswa.2022.200075.
- [96] Tim Jannusch et al. (2021). "Cars and distraction: How to address the limits of Driver Monitoring Systems and improve safety benefits using evidence from German young drivers". En: *Technology in Society*. DOI: 10.1016/j.techsoc.2021.101628.
- [97] Michalis Papakostas et al. (2021). "Understanding Driving Distractions: A Multimodal Analysis on Distraction Characterization". En: *Proceedings of the 26th International Conference on Intelligent User Interfaces*. DOI: 10.1145/3397481.3450635.
- [98] Qiang Hua et al. (2021). "Cognitive Distraction State Recognition of Drivers at a Nonsignalized Intersection in a Mixed Traffic Environment". En: *Advances in Civil Engineering*. DOI: 10.1155/2021/6676807.
- [99] Shengdi Chen et al. (2021). "Risky Driving Behavior Recognition Based on Vehicle Trajectory". En: *International Journal of Environmental Research and Public Health*. DOI: 10.3390/ijerph182312373.
- [100] M. Shahverdy et al. (2021). "Driver behaviour detection using 1D convolutional neural networks". En: *Electronics Letters*. DOI: 10.1049/ell2.12076.
- [101] S. Garcia-Herrero et al. (2021). "Assessment of the Influence of Technology-Based Distracted Driving on Drivers' Infractions and Their Subsequent Impact on Traffic Accidents Severity". En: *International Journal of Environmental Research and Public Health*. DOI: 10.3390/ijerph18137155.
- [102] E. Lattanzi y V. Freschi (2021). "Machine Learning Techniques to Identify Unsafe Driving Behavior by Means of In-Vehicle Sensor Data". En: *Expert Syst. Appl.* DOI: 10.1016/j.eswa.2021.114818.
- [103] Ziyang Xie, Li Li y Xu Xu (2021). "Real-Time Driving Distraction Recognition Through a Wrist-Mounted Accelerometer". En: *Human Factors: The Journal of Human Factors and Ergonomics Society*. DOI: 10.1177/0018720821995000.
- [104] Dongmei Shi y Hongyu Tang (2021). "Research on Safe Driving Evaluation Method Based on Machine Vision and Long Short-Term Memory Network". En: *J. Electr. Comput. Eng.* DOI: 10.1155/2021/9955079.
- [105] Jiawei Xu et al. (2021). "The Improvement of Road Driving Safety Guided by Visual Inattentional Blindness". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2020.3044927.
- [106] H. A. Ameen et al. (2021). "Identification of Driving Safety Profiles in Vehicle to Vehicle Communication System Based on Vehicle OBD Information". En: *Inf.* DOI: 10.3390/info12050194.
- [107] Landry Kezebou et al. (2021). "A deep neural network approach for detecting wrong-way driving incidents on highway roads". En: *No especificado*. DOI: 10.1117/12.2586039.
- [108] Qinyu Sun et al. (2020). "Research on a Cognitive Distraction Recognition Model for Intelligent Driving Systems Based on Real Vehicle Experiments". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s20164426.
- [109] J. Niu et al. (2020). "Study on drivers' visual perception characteristics during the take-over of vehicle control in automated driving". En: *Human Factors and Ergonomics in Manufacturing & Service Industries*. DOI: 10.1002/hfm.20860.

- [110] Dengbo He y Birsen Donmez (2020). "The Influence of Visual-Manual Distractions on Anticipatory Driving". En: *Human Factors: The Journal of Human Factors and Ergonomics Society*. DOI: 10.1177/0018720820938893.
- [111] E. Lattanzi, G. Castellucci y V. Freschi (2020). "Improving Machine Learning Identification of Unsafe Driver Behavior by Means of Sensor Fusion". En: *Applied Sciences*. DOI: 10.3390/app10186417.
- [112] Abbas Sheykhfard y F. Haghighi (2020). "Driver distraction by digital billboards? Structural equation modeling based on naturalistic driving study data: A case study of Iran." En: *Journal of safety research*. DOI: 10.1016/j.jsr.2019.11.002.
- [113] M. Shahverdy et al. (2020). "Driver behavior detection and classification using deep convolutional neural networks". En: *Expert Syst. Appl.* DOI: 10.1016/j.eswa.2020.113240.
- [114] Chen Huang et al. (2020). "HCF: A Hybrid CNN Framework for Behavior Detection of Distracted Drivers". En: *IEEE Access*. DOI: 10.1109/access.2020.3001159.
- [115] Zhenchao Ouyang et al. (2020). "Deep CNN-Based Real-Time Traffic Light Detector for Self-Driving Vehicles". En: *IEEE Transactions on Mobile Computing*. DOI: 10.1109/tmc.2019.2892451.
- [116] Ahmed Abu-Khadrah et al. (2025). "Drone-assisted adaptive object detection and privacy-preserving surveillance in smart cities using whale-optimized deep reinforcement learning techniques". En: *Scientific Reports*. DOI: 10.1038/s41598-025-94796-3.
- [117] Uttam U. Deshpande et al. (2025). "Computer-vision based automatic rider helmet violation detection and vehicle identification in Indian smart city scenarios using NVIDIA TAO toolkit and YOLOv8". En: *Frontiers in Artificial Intelligence*. DOI: 10.3389/frai.2025.1582257.
- [118] A. Elhenidy et al. (2025). "GY-YOLO: ghost separable YOLO for pedestrian detection". En: *Neural Computing and Applications*. DOI: 10.1007/s00521-025-11207-4.
- [119] T. Barbu y S. Bejinariu (2025). "Deep Learning-based Multiple Pedestrian Crossing Behavior Analysis Framework". En: *2025 IEEE/ACS 22nd International Conference on Computer Systems and Applications (AICCSA)*. DOI: 10.1109/aiccsa66935.2025.11315480.
- [120] A. Chouhan et al. (2025). "Deep Learning based enhanced aerial object detection". En: *Journal of Geomatics*. DOI: 10.58825/jog.2025.19.1.197.
- [121] O. Singh et al. (2025). "Real-time Identification of Traffic Violations through Deep Learning Techniques". En: *AVE Trends in Intelligent Computing Systems*. DOI: 10.64091/atcs.2025.000134.
- [122] A. Kavitha et al. (2025). "Towards Safer Roads: An End-to-End Deep Learning Framework for Traffic Violation Detection and License Plate Recognition". En: *Journal of Intelligent & Fuzzy Systems: Applications in Engineering and Technology*. DOI: 10.1177/18758967251397468.
- [123] Rohan V Rachoti et al. (2025). "Traffic Detection and Traffic Violation Detection using Deep Learning: An End-to-End YOLO-Based Framework". En: *2025 International Conference on Communication, Computer, and Information Technology (IC3IT)*. DOI: 10.1109/ic3it66137.2025.11340931.
- [124] Abdulkareem Abdullah et al. (2025). "LC-YOLO: An Improved YOLOv8-Based Lane Detection Model for Enhanced Lane Intrusion Detection". En: *IET Image Process.* DOI: 10.1049/ipr2.70065.
- [125] Bala Bhaskara et al. (2025). "Deep Learning-based Traffic Violation Detection using YOLOv8 and PaddleOCR". En: *2025 5th International Conference on Pervasive Computing and Social Networking (ICPCSN)*. DOI: 10.1109/icpcsn65854.2025.11035399.
- [126] Mahmoud Owais y M. Sayed (2025). "Red light crossing violations modelling using deep learning and variance-based sensitivity analysis". En: *Expert Syst. Appl.* DOI: 10.1016/j.eswa.2024.126258.
- [127] Swathi Gowroju et al. (2025). "UrbanEye: Deep Learning Enhanced Two-Wheeler Traffic Rule Violation Detection using YOLO and OCR". En: *2025 International Conference on Innovations in Intelligent Systems: Advancements in Computing, Communication, and Cybersecurity (ISAC3)*. DOI: 10.1109/isac364032.2025.11156855.
- [128] K. Pujitha et al. (2025). "Traffic Signal Violation Detection System". En: *International Journal of Scientific Research in Computer Science, Engineering and Information Technology*. DOI: 10.32628/cseit2511141.
- [129] K. Balasaranya et al. (2025). "Real-Time Traffic Violation Detection with Automated Enforcement Using Computer Vision". En: *2025 11th International Conference on Communication and Signal Processing (ICCSP)*. DOI: 10.1109/iccsp64183.2025.11089113.
- [130] Yanjie Wang y Lei Song (2025). "Application and Optimization of Convolutional Neural Networks Based on Deep Learning in Network Traffic Classification and Anomaly Detection". En: *Informatica (Slovenia)*. DOI: 10.31449/inf.v49i14.7602.
- [131] Sumith Reddy Kalwa (2025). "Detection of Unusual Activities on the Road Using Deep CNN". En: *International Journal for Research in Applied Science and Engineering Technology*. DOI: 10.22214/ijraset.2025.69790.
- [132] Carlos Eduardo Vazquez-Monjaras, Leonor Adriana Cardenas-Robledo y Carolina Reta (2024). "Detection of Unsafe Behavior in conveying Vehicle Parts using Computer Vision". En: *Engineering, Technology & Applied Science Research*. DOI: 10.48084/etasr.7530.
- [133] Oğuzhan Onal y E. Dandıl (2024). "Unsafe-Net: YOLO v4 and ConvLSTM based computer vision system

- for real-time detection of unsafe behaviours in workplace”. En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-024-19276-8.
- [134] Yan Ren (2024). “Intelligent Vehicle Violation Detection System Under Human–Computer Interaction and Computer Vision”. En: *International Journal of Computational Intelligence Systems*. DOI: 10.1007/s44196-024-00427-6.
- [135] Mei Liu y Leon Yang (2024). “IoT Network Traffic Analysis with Deep Learning”. En: *2024 IEEE International Conference on Pervasive Computing and Communications Workshops and other Affiliated Events (PerCom Workshops)*. DOI: 10.1109/percomworkshops59983.2024.10502498.
- [136] Renjith Thomas et al. (2024). “Automated Detection of Traffic Rule Violation using Deep Learning Techniques”. En: *2024 IEEE Recent Advances in Intelligent Computational Systems (RAICS)*. DOI: 10.1109/raics61201.2024.10690036.
- [137] Grishma Poudel (2024). “Improved Object Detection in UAV Images using Deep Learning”. En: *Cognizance Journal of Multidisciplinary Studies*. DOI: 10.47760/cognizance.2024.v04i07.009.
- [138] Alexander Michielsen et al. (2024). “History-Based Road Traffic Anomaly Detection Using Deep Learning and Real-World Data”. En: *No especificado*. DOI: 10.5220/0012565500003702.
- [139] Tom Driessen et al. (2024). “Putting ChatGPT vision (GPT-4V) to the test: risk perception in traffic images”. En: *Royal Society Open Science*. DOI: 10.1098/rsos.231676.
- [140] P. M. et al. (2024). “Traffic Rules Violation Detection System using YOLO v8 Model”. En: *2024 10th International Conference on Electrical Energy Systems (ICEES)*. DOI: 10.1109/icees61253.2024.10776906.
- [141] Nianfeng Li et al. (2024b). “Dense Pedestrian Detection Based on GR-YOLO”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s24144747.
- [142] Hitesh Gehani et al. (2024). “Traffic Signal Violation Detection System Using Computer Vision”. En: *Journal of Electrical Systems*. DOI: 10.52783/jes.2037.
- [143] Murat Bakirci (2024). “Enhancing vehicle detection in intelligent transportation systems via autonomous UAV platform and YOLOv8 integration”. En: *Appl. Soft Comput.* DOI: 10.1016/j.asoc.2024.112015.
- [144] E. Udayanti, Etika Kartikadarma y Fahri Firdausillah (2024). “Convolutional Neural Network and LSTM for Seat Belt Detection in Vehicles using YOLO3”. En: *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*. DOI: 10.29207/resti.v8i3.5784.
- [145] Maged Shoman et al. (2024). “Enforcing Traffic Safety: A Deep Learning Approach for Detecting Motorcyclists’ Helmet Violations Using YOLOv8 and Deep Convolutional Generative Adversarial Network-Generated Images”. En: *Algorithms*. DOI: 10.3390/a17050202.
- [146] J. H, B. R. y R. Rajalakshmi (2024). “Detection of Traffic Violation and Vehicle Number Plate Using Computer Vision”. En: *2024 International Conference on IoT, Communication and Automation Technology (ICICAT)*. DOI: 10.1109/icicat62666.2024.10923459.
- [147] Noor Ul Ain Tahir et al. (2024). “PVswin-YOLOv8s: UAV-Based Pedestrian and Vehicle Detection for Traffic Management in Smart Cities Using Improved YOLOv8”. En: *Drones*. DOI: 10.3390/drones8030084.
- [148] M. Samonte et al. (2024). “Grand challenge of image processing in automatic detection of vehicles running in red lights”. En: *No especificado*. DOI: 10.1117/12.3029380.
- [149] Luay Ibrahim Khalaf et al. (2024). “Deep Learning-Based Anomaly Detection in Network Traffic for Cyber Threat Identification”. En: *Proceedings of the Cognitive Models and Artificial Intelligence Conference*. DOI: 10.1145/3660853.3660932.
- [150] R. Ogundokun et al. (2024). “Development of a Deep Learning-Based System for Road Traffic Anomaly Detection”. En: *2024 International Conference on Science, Engineering and Business for Driving Sustainable Development Goals (SEB4SDG)*. DOI: 10.1109/seb4sdg60871.2024.10630004.
- [151] Nicolas Hernandez-Diaz et al. (2024). “A computer vision system for detecting motorcycle violations in pedestrian zones”. En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-024-19356-9.
- [152] Ghayth AlMahadin et al. (2024). “VANET Network Traffic Anomaly Detection Using GRU-Based Deep Learning Model”. En: *IEEE Transactions on Consumer Electronics*. DOI: 10.1109/tce.2023.3326384.
- [153] H. Fakhrrurroja et al. (2024). “A Vision-Based System: Detecting Traffic Law Violation Case Study of Red-Light Running Using Pre-Trained YOLOv8 Model and OpenCV”. En: *2024 IEEE International Conference on Smart Mechatronics (ICSMech)*. DOI: 10.1109/icsmech62936.2024.10812324.
- [154] Allabaksh Shaik y Shaik Mahaboob Basha (2024). “Optimal deep learning based object detection for pedestrian and anomaly recognition model”. En: *International Journal of Information Technology*. DOI: 10.1007/s41870-024-02075-7.
- [155] Xinyu Wu y Tingting Li (2024). “A deep learning-based car accident detection approach in video-based traffic surveillance”. En: *Journal of Optics*. DOI: 10.1007/s12596-023-01581-4.
- [156] Cesar Bartolome-Hornillos et al. (2024). “A Self-Adaptive Automatic Incident Detection System for Road Surveillance Based on Deep Learning”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s24061822.
- [157] Sarfaraz Natha et al. (2024). “Improving Traffic Surveillance: Deep Learning Approach for Road Anomaly

- Detection in Videos”. En: *2024 IEEE 3rd International Conference on Computing and Machine Intelligence (ICMI)*. DOI: 10.1109/icmi60790.2024.10585797.
- [158] M. Yazdani et al. (2023). “Intelligent vehicle pedestrian light (IVPL): A deep reinforcement learning approach for traffic signal control”. En: *Transportation Research Part C: Emerging Technologies*. DOI: 10.1016/j.trc.2022.103991.
- [159] Zenghui Qu et al. (2023). “Pedestrian Red-Light Violation Detection Based on Deep Learning Vision”. En: *2023 IEEE 6th International Conference on Automation, Electronics and Electrical Engineering (AU-TEEE)*. DOI: 10.1109/auteee60196.2023.10407497.
- [160] J. D. Fernandez et al. (2023). “Automated detection of vehicles with anomalous trajectories in traffic surveillance videos”. En: *Integrated Computer-Aided Engineering*. DOI: 10.3233/ica-230706.
- [161] Wanting Hu et al. (2023). “Research on Anomaly Network Detection Based on Self-Attention Mechanism”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23115059.
- [162] Mehwish Tahir et al. (2023). “Real-Time Event-Driven Road Traffic Monitoring System Using CCTV Video Analytics”. En: *IEEE Access*. DOI: 10.1109/access.2023.3340144.
- [163] Hyojung Ahn y Sonia Chung (2023). “Deep learning-based anomaly detection for individual drone vehicles performing swarm missions”. En: *Expert Syst. Appl.* DOI: 10.1016/j.eswa.2023.122869.
- [164] Darren Tangamus et al. (2023). “Method For Traffic Violation Detection Using Deep Learning”. En: *2023 International Conference on Informatics, Multimedia, Cyber and Informations System (ICIMCIS)*. DOI: 10.1109/icimcis60089.2023.10349009.
- [165] Hilmi Pradana (2023). “An End-to-End Online Traffic-Risk Incident Prediction in First-Person Dash Camera Videos”. En: *Big Data Cogn. Comput.* DOI: 10.3390/bdcc7030129.
- [166] Mahmoud Mastouri et al. (2023). “A Context-Aware, Computer-Vision-Based Approach for the Detection of Taxi Street-Hailing Scenes from Video Streams”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23104796.
- [167] Gelayol Golcarenenji et al. (2023). “Robust real-time traffic light detector on small-form platform for autonomous vehicles”. En: *Journal of Intelligent Transportation Systems*. DOI: 10.1080/15472450.2023.2205018.
- [168] Pooja Chaturvedi, Kruti Lavingia y Gaurang Raval (2023). “Detection of traffic rule violation in University campus using deep learning model”. En: *International Journal of System Assurance Engineering and Management*. DOI: 10.1007/s13198-023-02107-8.
- [169] Yung-Chung Wang et al. (2023). “Network Anomaly Intrusion Detection Based on Deep Learning Approach”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s23042171.
- [170] G. Madhavi et al. (2023). “Traffic Congestion Detection from Surveillance Videos using Deep Learning”. En: *2023 International Conference on Computer, Electronics & Electrical Engineering & their Applications (IC2E3)*. DOI: 10.1109/ic2e357697.2023.10262545.
- [171] Victor A. Adewopo y Nelly Elsayed (2023). “Smart City Transportation: Deep Learning Ensemble Approach for Traffic Accident Detection”. En: *IEEE Access*. DOI: 10.1109/access.2024.3387972.
- [172] Mohamed Yasir Mohamed Uvais, Vazeerudeen Abdul Hameed y Muhammad Ehsan Rana (2023). “Traffic Signal Violation Detection Through Computer Vision”. En: *2023 4th International Conference on Data Analytics for Business and Industry (ICDABI)*. DOI: 10.1109/icdabi60145.2023.10629616.
- [173] Ariba Zahid et al. (2023). “A data-driven approach for road accident detection in surveillance videos”. En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-023-16193-0.
- [174] J. D. Winter et al. (2023). “Predicting perceived risk of traffic scenes using computer vision”. En: *Transportation Research Part F: Traffic Psychology and Behaviour*. DOI: 10.1016/j.trf.2023.01.014.
- [175] D. Mane et al. (2023). “Real-Time Vehicle Accident Recognition from Traffic Video Surveillance using YOLOV8 and OpenCV”. En: *International Journal on Recent and Innovation Trends in Computing and Communication*. DOI: 10.17762/ijritcc.v11i5s.6651.
- [176] M. I. B. Ahmed et al. (2023b). “A Real-Time Computer Vision Based Approach to Detection and Classification of Traffic Incidents”. En: *Big Data Cogn. Comput.* DOI: 10.3390/bdcc7010022.
- [177] Tiago Tamagusko et al. (2022). “Deep Learning applied to Road Accident Detection with Transfer Learning and Synthetic Images”. En: *Transportation Research Procedia*. DOI: 10.1016/j.trpro.2022.09.012.
- [178] Zijiang Zhu et al. (2022). “Deep learning for autonomous vehicle and pedestrian interaction safety”. En: *Safety Science*. DOI: 10.1016/j.ssci.2021.105479.
- [179] Kruti Lavingia et al. (2022). “Machine Learning Based Approach for Traffic Rule Violation Detection”. En: *2022 IEEE 7th International Conference on Recent Advances and Innovations in Engineering (ICRAIE)*. DOI: 10.1109/icraie56454.2022.10054306.
- [180] Fu-Jun Du y Shuangjian Jiao (2022). “Improvement of Lightweight Convolutional Neural Network Model Based on YOLO Algorithm and Its Research in Pavement Defect Detection”. En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s22093537.
- [181] Xuewen Chen et al. (2022). “Research on Pedestrian Detection and DeepSort Tracking in Front of Intelligent Vehicle Based on Deep Learning”. En: *Sustainability*. DOI: 10.3390/su14159281.

- [182] Anan Yasamorn, Athasit Wongcharoen y C. Joochim (2022). "Object Detection of Pedestrian Crossing Accident Using Deep Convolutional Neural Networks". En: *2022 Research, Invention, and Innovation Congress: Innovative Electricals and Electronics (RI2C)*. DOI: 10.1109/ri2c56397.2022.9910331.
- [183] J. Cypto y P. Karthikeyan (2022). "Automatic detection system of speed violations in a traffic based on deep learning technique". En: *Journal of Intelligent & Fuzzy Systems*. DOI: 10.3233/jifs-220577.
- [184] Nader Al-Qubaydhi et al. (2022). "Detection of Unauthorized Unmanned Aerial Vehicles Using YOLOv5 and Transfer Learning". En: *Electronics*. DOI: 10.3390/electronics11172669.
- [185] L. Q. Thao et al. (2022). "Automatic Traffic Red-Light Violation Detection Using AI". En: *Ingenierie des systemes d information*. DOI: 10.18280/isi.270109.
- [186] M. Arshad y P. Kumar (2022). "Detection of Two-Wheeler Traffic Rule Violation Using Deep Learning". En: *2022 IEEE World Conference on Applied Intelligence and Computing (AIC)*. DOI: 10.1109/aic55036.2022.9848979.
- [187] Sardar Waqar Khan et al. (2022). "Anomaly Detection in Traffic Surveillance Videos Using Deep Learning". En: *Sensors (Basel, Switzerland)*. DOI: 10.3390/s22176563.
- [188] Hadi Ghahremannezhad, Hang Shi y Chengjun Liu (2022). "Real-Time Accident Detection in Traffic Surveillance Using Deep Learning". En: *2022 IEEE International Conference on Imaging Systems and Techniques (IST)*. DOI: 10.1109/ist55454.2022.9827736.
- [189] Yanzhao Zhu y Wei Yan (2022). "Traffic sign recognition based on deep learning". En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-022-12163-0.
- [190] V. Fedosov et al. (2021). "Method For Detecting Violation at a Pedestrian Crossing Using a Convolutional Neural Network". En: *2021 Radiation and Scattering of Electromagnetic Waves (RSEMW)*. DOI: 10.1109/rsemw52378.2021.9494089.
- [191] Usman Ahmed, Chun-Wei Lin y Gautam Srivastava (2021). "Unmanned Aerial Multi-Object Dynamic Frame Detection and Skipping Using Deep Learning on the Internet of Drones". En: *IEEE Internet of Things Magazine*. DOI: 10.1109/iotm.001.2100088.
- [192] Manu S. Pillai et al. (2021). "Real-time image enhancement for an automatic automobile accident detection through CCTV using deep learning". En: *Soft Computing*. DOI: 10.1007/s00500-021-05576-w.
- [193] L. Aversano et al. (2021). "Effective Anomaly Detection Using Deep Learning in IoT Systems". En: *Wireless Communications and Mobile Computing*. DOI: 10.1155/2021/9054336.
- [194] Karishma Pawar y V. Attar (2021). "Deep learning based detection and localization of road accidents from traffic surveillance videos". En: *ICT Express*. DOI: 10.1016/j.ict.2021.11.004.
- [195] Jalaja Tattari et al. (2021). "Deep Neural Networks Based Object Detection for Road Safety Using YOLO-V3". En: *Smart Computing Techniques and Applications*. DOI: 10.1007/978-981-16-0878-0_71.
- [196] A. Boukerche y Zhijun Hou (2021). "Object Detection Using Deep Learning Methods in Traffic Scenarios". En: *ACM Computing Surveys (CSUR)*. DOI: 10.1145/3434398.
- [197] Shi Dong, Yuanjun Xia y Tao Peng (2021). "Network Abnormal Traffic Detection Model Based on Semi-Supervised Deep Reinforcement Learning". En: *IEEE Transactions on Network and Service Management*. DOI: 10.1109/tnsm.2021.3120804.
- [198] Himanshu Gupta y O. Verma (2021). "Monitoring and surveillance of urban road traffic using low altitude drone images: a deep learning approach". En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-021-11146-x.
- [199] Armstrong Aboah et al. (2021). "A Vision-based System for Traffic Anomaly Detection using Deep Learning and Decision Trees". En: *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. DOI: 10.1109/cvprw53098.2021.00475.
- [200] Sergio Robles-Serrano, German Sanchez Torres y J. Branch (2021). "Automatic Detection of Traffic Accidents from Video Using Deep Learning Techniques". En: *Comput.* DOI: 10.3390/computers10110148.
- [201] S. Yu et al. (2020). "Scene-Graph Augmented Data-Driven Risk Assessment of Autonomous Vehicle Decisions". En: *IEEE Transactions on Intelligent Transportation Systems*. DOI: 10.1109/tits.2021.3074854.
- [202] Malin Svard, Jonas Bargman y T. Victor (2020). "Detection and response to critical lead vehicle deceleration events with peripheral vision: Glance response times are independent of visual eccentricity." En: *Accident; analysis and prevention*. DOI: 10.1016/j.aap.2020.105853.
- [203] Ruben J Franklin y Mohana (2020). "Traffic Signal Violation Detection using Artificial Intelligence and Deep Learning". En: *2020 5th International Conference on Communication and Electronics Systems (ICCES)*. DOI: 10.1109/iccес48766.2020.9137873.
- [204] S. K. Kumaran, D. Dogra y P. Roy (2020). "Anomaly Detection in Road Traffic Using Visual Surveillance". En: *ACM Computing Surveys (CSUR)*. DOI: 10.1145/3417989.
- [205] Aniruddha Tonge et al. (2020). "Traffic Rules Violation Detection using Deep Learning". En: *2020 4th International Conference on Electronics, Communication and Aerospace Technology (ICECA)*. DOI: 10.1109/iceca49313.2020.9297495.

- [206] Ren-Hung Hwang et al. (2020). “An Unsupervised Deep Learning Model for Early Network Traffic Anomaly Detection”. En: *IEEE Access*. DOI: 10.1109/access.2020.2973023.
- [207] N. Amma y S. Selvakumar (2020). “Anomaly detection framework for Internet of things traffic using vector convolutional deep learning approach in fog environment”. En: *Future Gener. Comput. Syst.* DOI: 10.1016/j.future.2020.07.020.
- [208] A. Micheal et al. (2020). “Object Detection and Tracking with UAV Data Using Deep Learning”. En: *Journal of the Indian Society of Remote Sensing*. DOI: 10.1007/s12524-020-01229-x.
- [209] Guanglu Wei y Zhonghua Wang (2020). “Adoption and realization of deep learning in network traffic anomaly detection device design”. En: *Soft Computing*. DOI: 10.1007/s00500-020-05210-1.
- [210] Maciej L. Pawelczyk y M. Wojtyra (2020). “Real World Object Detection Dataset for Quadcopter Unmanned Aerial Vehicle Detection”. En: *IEEE Access*. DOI: 10.1109/access.2020.3026192.
- [211] Dukka KarunKumar Reddy et al. (2020). “Deep neural network based anomaly detection in Internet of Things network traffic tracking for the applications of future smart cities”. En: *Transactions on Emerging Telecommunications Technologies*. DOI: 10.1002/ett.4121.
- [212] Amira Chriki et al. (2020). “Deep learning and hand-crafted features for one-class anomaly detection in UAV video”. En: *Multimedia Tools and Applications*. DOI: 10.1007/s11042-020-09774-w.
- [213] S. Kwon, Ho-Jin Jung y Kyoung-Dae Kim (2020). “Dynamic All-Red Signal Control Based on Deep Neural Network Considering Red Light Runner Characteristics”. En: *Applied Sciences*. DOI: 10.3390/app10176050.